

Tareas deep learning

Zaira Alejandra Forero Rojas

July 2026

Contents

1	Ejericicos Capitulo 2	3
1.1	Problema 2.1	3
1.2	Problema 2.2	4
1.3	Problema 2.3	7
2	Ejericicos Capitulo 3	9
2.1	Problema 3.1	9
2.2	Problema 3.2	11
2.3	Problema 3.3	11
2.4	Problema 3.4	15
2.5	Problema 3.5	17
2.6	Problema 3.6	18
2.7	Problema 3.7	20
2.8	Problema 3.8	21
2.9	Problema 3.8	24
2.10	Problema 3.9	25
2.11	Problema 3.10	25
2.12	Problema 3.11	26
2.13	Problema 3.12	27
2.14	Problema 3.13	28
2.15	Problema 3.14	29
2.16	Problema 3.15	29
2.17	Problema 3.16	30
2.18	Problema 3.17	31
2.19	Problema 3.18	33
3	Ejericicos Capitulo 4	34
3.1	Problema 4.1	34
3.2	Problema 4.2	35
3.3	Problema 4.3	36
3.4	Problema 4.4	38
3.5	Problema 4.5	39
3.6	Problema 4.6	40

3.7	Problema 4.7	41
3.8	Problema 4.8	42
3.9	Problema 4.8	45
3.10	Problema 4.9	45
3.11	Problema 4.10	46
3.12	Problema 4.11	47
4	Ejericicos Capitulo 5	49
4.1	Ejercicio 5.1	49
4.2	Ejercicio 5.2	50
4.3	Ejercicio 5.3	52
4.4	Ejercicio 5.4	53
4.5	Ejercicio 5.5	55
4.6	Ejercicio 5.6	56
4.7	Ejercicio 5.7	57
4.8	Ejercicio 5.8	58
4.9	Ejercicio 5.9	59
4.10	Ejercicio 5.10	60

1 Ejericicos Capitulo 2

1.1 Problema 2.1

El modelo de regresión lineal considerado es

$$f[x_i, \phi] = \phi_0 + \phi_1 x_i,$$

y su función de pérdida está dada por

$$L[\phi] = \sum_{i=1}^I (\phi_0 + \phi_1 x_i - y_i)^2.$$

Para simplificar la notación, definimos el error correspondiente al dato i como

$$e_i = \phi_0 + \phi_1 x_i - y_i.$$

Por lo tanto,

$$L[\phi] = \sum_{i=1}^I e_i^2.$$

Primero calculamos la derivada parcial respecto a ϕ_0 . Aplicando la regla de la cadena,

$$\frac{\partial L}{\partial \phi_0} = \sum_{i=1}^I 2e_i \frac{\partial e_i}{\partial \phi_0}.$$

Como

$$\frac{\partial e_i}{\partial \phi_0} = \frac{\partial}{\partial \phi_0} (\phi_0 + \phi_1 x_i - y_i) = 1,$$

se obtiene

$$\boxed{\frac{\partial L}{\partial \phi_0} = 2 \sum_{i=1}^I (\phi_0 + \phi_1 x_i - y_i)}.$$

Ahora derivamos respecto a ϕ_1 :

$$\frac{\partial L}{\partial \phi_1} = \sum_{i=1}^I 2e_i \frac{\partial e_i}{\partial \phi_1}.$$

En este caso,

$$\frac{\partial e_i}{\partial \phi_1} = \frac{\partial}{\partial \phi_1} (\phi_0 + \phi_1 x_i - y_i) = x_i.$$

Por consiguiente,

$$\frac{\partial L}{\partial \phi_1} = 2 \sum_{i=1}^I x_i (\phi_0 + \phi_1 x_i - y_i).$$

Estas dos derivadas forman el gradiente de la función de pérdida:

$$\nabla_{\phi} L = \begin{bmatrix} \frac{\partial L}{\partial \phi_0} \\ \frac{\partial L}{\partial \phi_1} \end{bmatrix} = \begin{bmatrix} 2 \sum_{i=1}^I (\phi_0 + \phi_1 x_i - y_i) \\ 2 \sum_{i=1}^I x_i (\phi_0 + \phi_1 x_i - y_i) \end{bmatrix}.$$

1.2 Problema 2.2

Para encontrar el mínimo de la función de pérdida, igualamos a cero las derivadas obtenidas en el problema anterior.

Comenzamos con

$$\frac{\partial L}{\partial \phi_0} = 0.$$

Entonces,

$$2 \sum_{i=1}^I (\phi_0 + \phi_1 x_i - y_i) = 0.$$

Dividiendo entre 2,

$$\sum_{i=1}^I (\phi_0 + \phi_1 x_i - y_i) = 0.$$

Distribuyendo la suma,

$$\sum_{i=1}^I \phi_0 + \phi_1 \sum_{i=1}^I x_i - \sum_{i=1}^I y_i = 0.$$

Como ϕ_0 no depende de i ,

$$I\phi_0 + \phi_1 \sum_{i=1}^I x_i = \sum_{i=1}^I y_i.$$

Por lo tanto,

$$\phi_0 = \frac{\sum_{i=1}^I y_i - \phi_1 \sum_{i=1}^I x_i}{I}.$$

Ahora utilizamos la segunda condición:

$$\frac{\partial L}{\partial \phi_1} = 0.$$

Esto da

$$2 \sum_{i=1}^I x_i (\phi_0 + \phi_1 x_i - y_i) = 0.$$

Dividiendo entre 2 y distribuyendo,

$$\phi_0 \sum_{i=1}^I x_i + \phi_1 \sum_{i=1}^I x_i^2 - \sum_{i=1}^I x_i y_i = 0.$$

Por tanto,

$$\phi_0 \sum_{i=1}^I x_i + \phi_1 \sum_{i=1}^I x_i^2 = \sum_{i=1}^I x_i y_i.$$

Sustituimos la expresión obtenida para ϕ_0 :

$$\left(\frac{\sum_{i=1}^I y_i - \phi_1 \sum_{i=1}^I x_i}{I} \right) \sum_{i=1}^I x_i + \phi_1 \sum_{i=1}^I x_i^2 = \sum_{i=1}^I x_i y_i.$$

Multiplicando toda la ecuación por I ,

$$\left(\sum_{i=1}^I x_i \right) \left(\sum_{i=1}^I y_i \right) - \phi_1 \left(\sum_{i=1}^I x_i \right)^2 + I \phi_1 \sum_{i=1}^I x_i^2 = I \sum_{i=1}^I x_i y_i.$$

Agrupando los términos que contienen a ϕ_1 ,

$$\phi_1 \left[I \sum_{i=1}^I x_i^2 - \left(\sum_{i=1}^I x_i \right)^2 \right] = I \sum_{i=1}^I x_i y_i - \left(\sum_{i=1}^I x_i \right) \left(\sum_{i=1}^I y_i \right).$$

Finalmente,

$$\hat{\phi}_1 = \frac{I \sum_{i=1}^I x_i y_i - \left(\sum_{i=1}^I x_i \right) \left(\sum_{i=1}^I y_i \right)}{I \sum_{i=1}^I x_i^2 - \left(\sum_{i=1}^I x_i \right)^2}.$$

Una vez calculada la pendiente, el intercepto es

$$\hat{\phi}_0 = \frac{\sum_{i=1}^I y_i - \hat{\phi}_1 \sum_{i=1}^I x_i}{I}.$$

Usando las medias

$$\bar{x} = \frac{1}{I} \sum_{i=1}^I x_i, \quad \bar{y} = \frac{1}{I} \sum_{i=1}^I y_i,$$

estas expresiones también pueden escribirse de una forma más conocida:

$$\hat{\phi}_1 = \frac{\sum_{i=1}^I (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^I (x_i - \bar{x})^2}$$

y

$$\hat{\phi}_0 = \bar{y} - \hat{\phi}_1 \bar{x}.$$

La solución es única siempre que los valores x_i no sean todos iguales. En efecto, la matriz hessiana de la pérdida es

$$H = 2 \begin{bmatrix} I & \sum_{i=1}^I x_i \\ \sum_{i=1}^I x_i & \sum_{i=1}^I x_i^2 \end{bmatrix}.$$

Su determinante es

$$\det(H) = 4 \left[I \sum_{i=1}^I x_i^2 - \left(\sum_{i=1}^I x_i \right)^2 \right].$$

Además,

$$I \sum_{i=1}^I x_i^2 - \left(\sum_{i=1}^I x_i \right)^2 = I \sum_{i=1}^I (x_i - \bar{x})^2.$$

Esta cantidad es positiva cuando existe variación entre los valores x_i . Por ello, la pérdida es convexa y el punto encontrado corresponde al mínimo global.

1.3 Problema 2.3

En el modelo discriminativo original se intenta predecir y a partir de x :

$$y = f[x, \phi] = \phi_0 + \phi_1 x.$$

Ahora se propone invertir el papel de las variables y construir el modelo generativo

$$x = g[y, \phi] = \phi_0 + \phi_1 y.$$

Como el modelo ahora predice x_i a partir de y_i , la nueva función de pérdida debe medir la diferencia entre el valor estimado de x_i y su valor real. Por tanto,

$$L_g[\phi] = \sum_{i=1}^I (g[y_i, \phi] - x_i)^2 = \sum_{i=1}^I (\phi_0 + \phi_1 y_i - x_i)^2.$$

Después de ajustar el modelo, para realizar inferencia necesitamos obtener y a partir de un valor de x . Partimos de

$$x = \phi_0 + \phi_1 y.$$

Restando ϕ_0 ,

$$x - \phi_0 = \phi_1 y.$$

Si $\phi_1 \neq 0$, dividimos entre ϕ_1 :

$$y = g^{-1}[x, \phi] = \frac{x - \phi_0}{\phi_1}.$$

Aunque ambos modelos describen una recta, en general no producen el mismo ajuste.

El modelo discriminativo minimiza los errores en la dirección de y :

$$\sum_{i=1}^I (\phi_0 + \phi_1 x_i - y_i)^2.$$

En cambio, el modelo generativo minimiza los errores en la dirección de x :

$$\sum_{i=1}^I (\phi_0 + \phi_1 y_i - x_i)^2.$$

Para verlo de manera algebraica, definimos

$$S_{xx} = \sum_{i=1}^I (x_i - \bar{x})^2,$$

$$S_{yy} = \sum_{i=1}^I (y_i - \bar{y})^2,$$

y

$$S_{xy} = \sum_{i=1}^I (x_i - \bar{x})(y_i - \bar{y}).$$

La pendiente obtenida al ajustar directamente y en función de x es

$$\hat{\phi}_1^{(d)} = \frac{S_{xy}}{S_{xx}}.$$

Por otro lado, al ajustar x en función de y , la pendiente es

$$\hat{\phi}_1^{(g)} = \frac{S_{xy}}{S_{yy}}.$$

Sin embargo, después de invertir el modelo generativo, la pendiente de y respecto a x pasa a ser

$$\tilde{\phi}_1 = \frac{1}{\hat{\phi}_1^{(g)}} = \frac{S_{yy}}{S_{xy}}.$$

Para que ambas pendientes fueran iguales tendría que cumplirse

$$\frac{S_{xy}}{S_{xx}} = \frac{S_{yy}}{S_{xy}},$$

es decir,

$$S_{xy}^2 = S_{xx}S_{yy}.$$

Esta igualdad solamente se presenta cuando los datos están perfectamente alineados sobre una recta, salvo casos degenerados. Por lo tanto, cuando existen errores o ruido en los datos, los dos métodos normalmente entregan rectas diferentes.

Consideremos, por ejemplo, los tres puntos

$$(0, 0), \quad (1, 1), \quad (2, 3).$$

Al ajustar directamente y en función de x , se obtiene

$$\hat{y} = -\frac{1}{6} + \frac{3}{2}x.$$

En cambio, al ajustar x en función de y , se obtiene

$$\hat{x} = \frac{1}{7} + \frac{9}{14}y.$$

Invirtiendo esta última expresión,

$$y = \frac{x - \frac{1}{7}}{\frac{9}{14}} = -\frac{2}{9} + \frac{14}{9}x.$$

Por tanto, las rectas obtenidas son

$$\hat{y} = -\frac{1}{6} + \frac{3}{2}x$$

y

$$\tilde{y} = -\frac{2}{9} + \frac{14}{9}x,$$

las cuales no son iguales. Esto confirma que cambiar la dirección de la regresión y luego invertir el resultado no produce, en general, el mismo modelo.

2 Ejercicios Capitulo 3

2.1 Problema 3.1

La red neuronal de la ecuación (3.1) tiene la forma

$$y = f[x, \phi] = \phi_0 + \phi_1 a[\theta_{10} + \theta_{11}x] + \phi_2 a[\theta_{20} + \theta_{21}x] + \phi_3 a[\theta_{30} + \theta_{31}x].$$

Para hacer más corta la escritura, definimos

$$z_1 = \theta_{10} + \theta_{11}x, \quad z_2 = \theta_{20} + \theta_{21}x, \quad z_3 = \theta_{30} + \theta_{31}x.$$

Supongamos primero que la función de activación también es lineal:

$$a[z] = \psi_0 + \psi_1 z.$$

Entonces, las salidas de las tres unidades ocultas son

$$h_1 = \psi_0 + \psi_1(\theta_{10} + \theta_{11}x),$$

$$h_2 = \psi_0 + \psi_1(\theta_{20} + \theta_{21}x),$$

y

$$h_3 = \psi_0 + \psi_1(\theta_{30} + \theta_{31}x).$$

Sustituyendo estas expresiones en la salida de la red se obtiene

$$\begin{aligned} y = & \phi_0 + \phi_1 [\psi_0 + \psi_1(\theta_{10} + \theta_{11}x)] \\ & + \phi_2 [\psi_0 + \psi_1(\theta_{20} + \theta_{21}x)] \\ & + \phi_3 [\psi_0 + \psi_1(\theta_{30} + \theta_{31}x)]. \end{aligned}$$

Distribuyendo los pesos,

$$\begin{aligned}
y = & \phi_0 + \phi_1\psi_0 + \phi_1\psi_1\theta_{10} + \phi_1\psi_1\theta_{11}x \\
& + \phi_2\psi_0 + \phi_2\psi_1\theta_{20} + \phi_2\psi_1\theta_{21}x \\
& + \phi_3\psi_0 + \phi_3\psi_1\theta_{30} + \phi_3\psi_1\theta_{31}x.
\end{aligned}$$

Agrupamos primero los términos que no dependen de x :

$$\beta_0 = \phi_0 + \psi_0(\phi_1 + \phi_2 + \phi_3) + \psi_1(\phi_1\theta_{10} + \phi_2\theta_{20} + \phi_3\theta_{30}),$$

y después los términos que acompañan a x :

$$\beta_1 = \psi_1(\phi_1\theta_{11} + \phi_2\theta_{21} + \phi_3\theta_{31}).$$

Por tanto, toda la red se reduce a

$$\boxed{y = \beta_0 + \beta_1 x}.$$

Es decir, aunque la red tiene tres unidades ocultas, al usar una activación lineal solamente se obtiene una recta. No aparecen quiebres ni regiones lineales diferentes.

Ahora consideremos el caso en el que se elimina la función de activación, de manera que

$$a[z] = z.$$

Esto equivale a tomar

$$\psi_0 = 0, \quad \psi_1 = 1.$$

La salida se convierte en

$$\begin{aligned}
y = & \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x) \\
& + \phi_3(\theta_{30} + \theta_{31}x).
\end{aligned}$$

Agrupando nuevamente,

$$\boxed{y = (\phi_0 + \phi_1\theta_{10} + \phi_2\theta_{20} + \phi_3\theta_{30}) + (\phi_1\theta_{11} + \phi_2\theta_{21} + \phi_3\theta_{31})x}.$$

Por lo tanto, en los dos casos se obtiene una función lineal de la entrada. La diferencia está únicamente en los valores efectivos del intercepto y de la pendiente.

Esto muestra por qué se necesita una función de activación no lineal: sin ella, añadir unidades ocultas no permite construir funciones más complicadas que una recta.

2.2 Problema 3.2

Cada unidad oculta está dada por

$$h_i = \text{ReLU} [\theta_{i0} + \theta_{i1}x] .$$

Una unidad está activa cuando su preactivación es positiva:

$$\theta_{i0} + \theta_{i1}x > 0,$$

y está inactiva cuando

$$\theta_{i0} + \theta_{i1}x \leq 0.$$

En la figura 3.3j aparecen tres puntos de cambio, que denotaremos por

$$x_1^* < x_2^* < x_3^*.$$

Siguiendo la figura de izquierda a derecha, las unidades activas e inactivas son

Región	Unidades activas	Unidades inactivas
$x < x_1^*$	h_3	h_1, h_2
$x_1^* < x < x_2^*$	h_1, h_3	h_2
$x_2^* < x < x_3^*$	h_1, h_2, h_3	ninguna
$x > x_3^*$	h_1, h_2	h_3

En la primera región solamente contribuye h_3 . Al cruzar el primer punto de cambio se activa h_1 . Después se activa h_2 y, al cruzar el último punto, h_3 deja de estar activa.

En los puntos exactos x_i^* , la preactivación correspondiente es cero. Como

$$\text{ReLU}(0) = 0,$$

la contribución de esa unidad en el punto de cambio también es cero. Esto permite que la función final sea continua, aunque su pendiente cambie.

2.3 Problema 3.3

La función representada por la red es

$$f[x, \phi] = \phi_0 + \phi_1 h_1 + \phi_2 h_2 + \phi_3 h_3,$$

donde

$$h_1 = \text{ReLU} [\theta_{10} + \theta_{11}x],$$

$$h_2 = \text{ReLU} [\theta_{20} + \theta_{21}x],$$

y

$$h_3 = \text{ReLU} [\theta_{30} + \theta_{31}x].$$

Posiciones horizontales de los puntos de cambio

Cada punto de cambio aparece cuando la entrada de una unidad oculta es igual a cero.

Para la primera unidad,

$$\theta_{10} + \theta_{11}x_1^* = 0.$$

Despejando x_1^* ,

$$x_1^* = -\frac{\theta_{10}}{\theta_{11}}.$$

Para la segunda unidad,

$$\theta_{20} + \theta_{21}x_2^* = 0,$$

de donde

$$x_2^* = -\frac{\theta_{20}}{\theta_{21}}.$$

Finalmente, para la tercera unidad,

$$\theta_{30} + \theta_{31}x_3^* = 0,$$

y, por tanto,

$$x_3^* = -\frac{\theta_{30}}{\theta_{31}}.$$

Estas expresiones suponen que

$$\theta_{11} \neq 0, \quad \theta_{21} \neq 0, \quad \theta_{31} \neq 0.$$

En la figura 3.3 se cumple el orden

$$-\frac{\theta_{10}}{\theta_{11}} < -\frac{\theta_{20}}{\theta_{21}} < -\frac{\theta_{30}}{\theta_{31}}.$$

Además, las primeras dos unidades se activan al avanzar hacia la derecha, mientras que la tercera se desactiva. Por eso se tiene

$$\theta_{11} > 0, \quad \theta_{21} > 0, \quad \theta_{31} < 0.$$

Posiciones verticales de los puntos de cambio

En el primer punto, $h_1 = 0$, mientras que h_2 está inactiva y h_3 está activa. Por consiguiente,

$$y_1^* = \phi_0 + \phi_3 (\theta_{30} + \theta_{31}x_1^*).$$

Sustituyendo

$$x_1^* = -\frac{\theta_{10}}{\theta_{11}},$$

obtenemos

$$y_1^* = \phi_0 + \phi_3 \left(\theta_{30} - \frac{\theta_{31}\theta_{10}}{\theta_{11}} \right).$$

Por tanto, las coordenadas del primer punto son

$$\left(-\frac{\theta_{10}}{\theta_{11}}, \phi_0 + \phi_3 \left(\theta_{30} - \frac{\theta_{31}\theta_{10}}{\theta_{11}} \right) \right).$$

En el segundo punto se cumple $h_2 = 0$, pero h_1 y h_3 están activas. Entonces,

$$y_2^* = \phi_0 + \phi_1 (\theta_{10} + \theta_{11}x_2^*) + \phi_3 (\theta_{30} + \theta_{31}x_2^*).$$

Como

$$x_2^* = -\frac{\theta_{20}}{\theta_{21}},$$

se obtiene

$$y_2^* = \phi_0 + \phi_1 \left(\theta_{10} - \frac{\theta_{11}\theta_{20}}{\theta_{21}} \right) + \phi_3 \left(\theta_{30} - \frac{\theta_{31}\theta_{20}}{\theta_{21}} \right).$$

Así, el segundo punto es

$$\left(-\frac{\theta_{20}}{\theta_{21}}, y_2^* \right).$$

En el tercer punto, $h_3 = 0$, mientras que h_1 y h_2 están activas. Por tanto,

$$y_3^* = \phi_0 + \phi_1 (\theta_{10} + \theta_{11}x_3^*) + \phi_2 (\theta_{20} + \theta_{21}x_3^*).$$

Sustituyendo

$$x_3^* = -\frac{\theta_{30}}{\theta_{31}},$$

resulta

$$y_3^* = \phi_0 + \phi_1 \left(\theta_{10} - \frac{\theta_{11}\theta_{30}}{\theta_{31}} \right) + \phi_2 \left(\theta_{20} - \frac{\theta_{21}\theta_{30}}{\theta_{31}} \right).$$

Por consiguiente, el tercer punto es

$$\left(-\frac{\theta_{30}}{\theta_{31}}, y_3^* \right).$$

Pendientes de las cuatro regiones

Cuando una unidad está activa, su salida es

$$h_i = \theta_{i0} + \theta_{i1}x,$$

por lo que su derivada respecto a x es

$$\frac{dh_i}{dx} = \theta_{i1}.$$

Si la unidad está inactiva, entonces $h_i = 0$ y su derivada también es cero. De manera general, la pendiente de la salida puede escribirse como

$$\frac{df}{dx} = \sum_{i=1}^3 \phi_i \theta_{i1} \mathbb{I}(\theta_{i0} + \theta_{i1}x > 0),$$

donde $\mathbb{I}(\cdot)$ vale uno cuando la condición se cumple y cero en caso contrario. En la primera región solamente está activa h_3 . La función es

$$f_1(x) = \phi_0 + \phi_3(\theta_{30} + \theta_{31}x),$$

y su pendiente es

$$m_1 = \phi_3 \theta_{31}.$$

En la segunda región están activas h_1 y h_3 :

$$f_2(x) = \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_3(\theta_{30} + \theta_{31}x).$$

Por tanto,

$$m_2 = \phi_1 \theta_{11} + \phi_3 \theta_{31}.$$

En la tercera región están activas las tres unidades:

$$f_3(x) = \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x) + \phi_3(\theta_{30} + \theta_{31}x).$$

La pendiente es

$$m_3 = \phi_1\theta_{11} + \phi_2\theta_{21} + \phi_3\theta_{31}.$$

Finalmente, en la cuarta región están activas h_1 y h_2 , pero h_3 está inactiva:

$$f_4(x) = \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x).$$

Entonces,

$$m_4 = \phi_1\theta_{11} + \phi_2\theta_{21}.$$

En resumen,

$$f(x) = \begin{cases} \phi_0 + \phi_3(\theta_{30} + \theta_{31}x), & x < x_1^*, \\ \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_3(\theta_{30} + \theta_{31}x), & x_1^* \leq x < x_2^*, \\ \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x) + \phi_3(\theta_{30} + \theta_{31}x), & x_2^* \leq x < x_3^*, \\ \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x), & x \geq x_3^*. \end{cases}$$

2.4 Problema 3.4

En la figura 3.3 original, la tercera preactivación tiene pendiente negativa. Esto hace que la tercera unidad esté activa en la parte izquierda y se desactive al pasar por su punto de cambio.

Ahora se reemplaza esta preactivación por la mostrada en la figura 3.14c. La nueva preactivación será denotada por

$$\tilde{z}_3 = \tilde{\theta}_{30} + \tilde{\theta}_{31}x,$$

donde, según la nueva gráfica,

$$\tilde{\theta}_{30} < 0, \quad \tilde{\theta}_{31} > 0.$$

Su nuevo punto de cambio se encuentra resolviendo

$$\tilde{\theta}_{30} + \tilde{\theta}_{31}\tilde{x}_3^* = 0.$$

Por tanto,

$$\tilde{x}_3^* = -\frac{\tilde{\theta}_{30}}{\tilde{\theta}_{31}}.$$

Como la pendiente ahora es positiva, la tercera unidad permanece inactiva antes de este punto y se activa después:

$$\tilde{h}_3 = \text{ReLU}[\tilde{\theta}_{30} + \tilde{\theta}_{31}x] = \begin{cases} 0, & x \leq \tilde{x}_3^*, \\ \tilde{\theta}_{30} + \tilde{\theta}_{31}x, & x > \tilde{x}_3^*. \end{cases}$$

Las primeras dos unidades no cambian:

$$h_1 = \text{ReLU} [\theta_{10} + \theta_{11}x],$$

$$h_2 = \text{ReLU} [\theta_{20} + \theta_{21}x].$$


La nueva salida de la red es

$$\boxed{\tilde{f}(x) = \phi_0 + \phi_1 h_1 + \phi_2 h_2 + \phi_3 \tilde{h}_3}.$$

Suponiendo que el nuevo punto de cambio sigue estando después de los otros dos,

$$x_1^* < x_2^* < \tilde{x}_3^*,$$

la actividad de las unidades puede representarse mediante el siguiente esquema:



La función resultante puede escribirse por regiones como

$$\tilde{f}(x) = \begin{cases} \phi_0, & x < x_1^*, \\ \phi_0 + \phi_1(\theta_{10} + \theta_{11}x), & x_1^* \leq x < x_2^*, \\ \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x), & x_2^* \leq x < \tilde{x}_3^*, \\ \phi_0 + \phi_1(\theta_{10} + \theta_{11}x) + \phi_2(\theta_{20} + \theta_{21}x) + \phi_3 \left(\tilde{\theta}_{30} + \tilde{\theta}_{31}x \right), & x \geq \tilde{x}_3^*. \end{cases}$$

Las pendientes de las cuatro regiones son ahora

$$\boxed{\tilde{m}_1 = 0},$$

$$\boxed{\tilde{m}_2 = \phi_1 \theta_{11}},$$

$$\boxed{\tilde{m}_3 = \phi_1 \theta_{11} + \phi_2 \theta_{21}},$$

y

$$\boxed{\tilde{m}_4 = \phi_1 \theta_{11} + \phi_2 \theta_{21} + \phi_3 \tilde{\theta}_{31}}.$$

El cambio principal se observa en los extremos de la función. En la figura original, h_3 contribuía en la primera región y dejaba de contribuir en la última. Con la nueva recta ocurre lo contrario: h_3 no contribuye al comienzo y empieza a contribuir en la última región.

Por eso, la nueva función comienza horizontalmente en

$$\tilde{f}(x) = \phi_0,$$

y recibe una nueva contribución de pendiente al cruzar $\tilde{x}_3^*$.

2.5 Problema 3.5

La función ReLU se define como

$$\text{ReLU}(z) = \max(0, z) = \begin{cases} 0, & z < 0, \\ z, & z \geq 0. \end{cases}$$

Queremos demostrar que, para todo $\alpha > 0$,

$$\text{ReLU}(\alpha z) = \alpha \text{ReLU}(z).$$

La demostración puede hacerse separando los posibles signos de z .

Caso 1: $z \geq 0$

Como $\alpha > 0$, al multiplicar z por α se conserva su signo. Por tanto,

$$\alpha z \geq 0.$$

Usando la definición de ReLU,

$$\text{ReLU}(\alpha z) = \alpha z.$$

Además, como $z \geq 0$,

$$\text{ReLU}(z) = z.$$

Multiplicando por α ,

$$\alpha \text{ReLU}(z) = \alpha z.$$

De esta manera,

$$\text{ReLU}(\alpha z) = \alpha \text{ReLU}(z).$$

Caso 2: $z < 0$

Nuevamente, como $\alpha > 0$, la multiplicación por α no cambia el signo de z . Por ello,

$$\alpha z < 0.$$

Entonces,

$$\text{ReLU}(\alpha z) = 0.$$

Por otro lado,

$$\text{ReLU}(z) = 0,$$

y por tanto,

$$\alpha \text{ReLU}(z) = \alpha \cdot 0 = 0.$$

Así,

$$\text{ReLU}(\alpha z) = \alpha \text{ReLU}(z).$$

Como la igualdad se cumple tanto para $z \geq 0$ como para $z < 0$, podemos concluir que

$$\boxed{\text{ReLU}(\alpha z) = \alpha \text{ReLU}(z), \quad \alpha > 0}.$$

También puede demostrarse directamente usando la definición con el máximo:

$$\begin{aligned} \text{ReLU}(\alpha z) &= \max(0, \alpha z) \\ &= \alpha \max(0, z) \\ &= \alpha \text{ReLU}(z). \end{aligned}$$

La segunda igualdad es válida porque α es positivo y, por tanto, puede sacarse del máximo sin cambiar el orden de los valores.

Esta propiedad se conoce como homogeneidad no negativa de la función ReLU. Si se permite $\alpha = 0$, la propiedad también se cumple, pues ambos lados de la igualdad son cero.

2.6 Problema 3.6

La primera unidad oculta de la red está dada por

$$h_1 = \text{ReLU}(\theta_{10} + \theta_{11}x).$$

La contribución de esta unidad a la salida es

$$\phi_1 h_1 = \phi_1 \text{ReLU}(\theta_{10} + \theta_{11}x).$$

Ahora multiplicamos los parámetros θ_{10} y θ_{11} por una constante α , y dividimos el parámetro ϕ_1 entre la misma constante:

$$\tilde{\theta}_{10} = \alpha \theta_{10}, \quad \tilde{\theta}_{11} = \alpha \theta_{11}, \quad \tilde{\phi}_1 = \frac{\phi_1}{\alpha}.$$

La nueva contribución de la primera unidad es

$$\begin{aligned}\tilde{\phi}_1 \tilde{h}_1 &= \frac{\phi_1}{\alpha} \text{ReLU}(\alpha \theta_{10} + \alpha \theta_{11} x) \\ &= \frac{\phi_1}{\alpha} \text{ReLU}[\alpha (\theta_{10} + \theta_{11} x)].\end{aligned}$$

Cuando $\alpha > 0$, se puede utilizar la propiedad de homogeneidad no negativa de ReLU:

$$\text{ReLU}(\alpha z) = \alpha \text{ReLU}(z).$$

Entonces,

$$\begin{aligned}\tilde{\phi}_1 \tilde{h}_1 &= \frac{\phi_1}{\alpha} \alpha \text{ReLU}(\theta_{10} + \theta_{11} x) \\ &= \phi_1 \text{ReLU}(\theta_{10} + \theta_{11} x) \\ &= \phi_1 h_1.\end{aligned}$$

Por tanto, si $\alpha > 0$, la función representada por la red no cambia:

$$\boxed{\tilde{f}(x) = f(x)}.$$

Esto muestra que diferentes conjuntos de parámetros pueden representar exactamente la misma función.

Ahora consideremos el caso $\alpha < 0$. Podemos escribir

$$\alpha = -\beta, \quad \beta > 0.$$

Entonces,

$$\text{ReLU}(\alpha z) = \text{ReLU}(-\beta z) = \beta \text{ReLU}(-z).$$

Como $\beta = -\alpha$,

$$\text{ReLU}(\alpha z) = -\alpha \text{ReLU}(-z).$$

La nueva contribución será

$$\begin{aligned}\tilde{\phi}_1 \tilde{h}_1 &= \frac{\phi_1}{\alpha} \text{ReLU}(\alpha z) \\ &= \frac{\phi_1}{\alpha} [-\alpha \text{ReLU}(-z)] \\ &= -\phi_1 \text{ReLU}(-z),\end{aligned}$$

donde

$$z = \theta_{10} + \theta_{11} x.$$

En general,

$$-\phi_1 \text{ReLU}(-z) \neq \phi_1 \text{ReLU}(z).$$

Por tanto, cuando $\alpha < 0$, la salida de la red sí cambia:

$$\boxed{\tilde{f}(x) \neq f(x) \quad \text{en general.}}$$

El punto donde se encuentra el quiebre no cambia, porque

$$\alpha(\theta_{10} + \theta_{11}x) = 0$$

tiene la misma solución que

$$\theta_{10} + \theta_{11}x = 0.$$

Sin embargo, se invierte el lado en el que la unidad está activa.

2.7 Problema 3.7

La función de pérdida por mínimos cuadrados es

$$L(\phi) = \sum_{i=1}^I (f[x_i, \phi] - y_i)^2.$$

El mínimo de esta función no tiene que corresponder a un único conjunto de parámetros.

Como se mostró en el problema anterior, la contribución de una unidad oculta puede escribirse como

$$\phi_d \text{ReLU}(\theta_{d0} + \theta_{d1}x).$$

Para cualquier $\alpha > 0$, se puede realizar el cambio

$$\theta_{d0} \longrightarrow \alpha\theta_{d0},$$

$$\theta_{d1} \longrightarrow \alpha\theta_{d1},$$

y

$$\phi_d \longrightarrow \frac{\phi_d}{\alpha}.$$

Por la homogeneidad de ReLU,

$$\begin{aligned} \frac{\phi_d}{\alpha} \text{ReLU}[\alpha(\theta_{d0} + \theta_{d1}x)] &= \frac{\phi_d}{\alpha} \alpha \text{ReLU}(\theta_{d0} + \theta_{d1}x) \\ &= \phi_d \text{ReLU}(\theta_{d0} + \theta_{d1}x). \end{aligned}$$

Todos estos valores positivos de α producen la misma función y, por tanto, el mismo valor de la pérdida.

También se puede cambiar el orden de las unidades ocultas. Por ejemplo,

$$(\theta_{10}, \theta_{11}, \phi_1) \longleftrightarrow (\theta_{20}, \theta_{21}, \phi_2).$$

La suma

$$\phi_1 h_1 + \phi_2 h_2 + \phi_3 h_3$$

no cambia al intercambiar dos unidades completas. Con tres unidades ocultas existen

$$3! = 6$$

posibles permutaciones.

Por tanto, incluso cuando existe una única función que se ajusta mejor a los datos, normalmente hay varios conjuntos de parámetros que representan esa misma función.

En conclusión,

la función de pérdida no tiene, en general, un mínimo único en el espacio de parámetros.

2.8 Problema 3.8

Los parámetros de la red son

$$\begin{aligned}\phi_0 &= -0.23, & \phi_1 &= -1.3, & \phi_2 &= 1.3, & \phi_3 &= 0.66, \\ \theta_{10} &= -0.2, & \theta_{11} &= 0.4, & \theta_{20} &= -0.9, & \theta_{21} &= 0.9, \\ \theta_{30} &= 1.1, & \theta_{31} &= -0.7.\end{aligned}$$

Las tres preactivaciones de la red son

$$z_1 = -0.2 + 0.4x,$$

$$z_2 = -0.9 + 0.9x,$$

y

$$z_3 = 1.1 - 0.7x.$$

Para una función de activación general $a(\cdot)$, la salida de la red es

$$f_a(x) = -0.23 - 1.3a(-0.2 + 0.4x) + 1.3a(-0.9 + 0.9x) + 0.66a(1.1 - 0.7x).$$

Función escalón de Heaviside

La función de Heaviside se define como

$$\text{heaviside}(z) = \begin{cases} 0, & z < 0, \\ 1, & z \geq 0. \end{cases}$$

Los puntos en los que cambian las unidades ocultas son

$$-0.2 + 0.4x = 0 \implies x = \frac{1}{2},$$

$$-0.9 + 0.9x = 0 \implies x = 1,$$

y

$$1.1 - 0.7x = 0 \implies x = \frac{11}{7}.$$

La salida queda

$$f_H(x) = -0.23 - 1.3 \operatorname{heaviside}(-0.2 + 0.4x) + 1.3 \operatorname{heaviside}(-0.9 + 0.9x) + 0.66 \operatorname{heaviside}(1.1 - 0.7x).$$

Por regiones,

$$f_H(x) = \begin{cases} 0.43, & x < \frac{1}{2}, \\ -0.87, & \frac{1}{2} \leq x < 1, \\ 0.43, & 1 \leq x \leq \frac{11}{7}, \\ -0.23, & x > \frac{11}{7}. \end{cases}$$

La red produce una función constante por partes. Cada unidad introduce un salto cuando su entrada cruza por cero.

Función tangente hiperbólica

En este caso,

$$a(z) = \tanh(z).$$

La salida es

$$f_{\tanh}(x) = -0.23 - 1.3 \tanh(-0.2 + 0.4x) + 1.3 \tanh(-0.9 + 0.9x) + 0.66 \tanh(1.1 - 0.7x).$$

La tangente hiperbólica es continua y suave. Por esta razón, la salida de la red también es una función continua y suave. En lugar de producir quiebres, cada unidad genera una transición gradual.

Función rectangular

La función rectangular se define como

$$\operatorname{rect}(z) = \begin{cases} 0, & z < 0, \\ 1, & 0 \leq z \leq 1, \\ 0, & z > 1. \end{cases}$$

Para la primera unidad se necesita que

$$0 \leq -0.2 + 0.4x \leq 1.$$

Sumando 0.2,

$$0.2 \leq 0.4x \leq 1.2.$$

Dividiendo entre 0.4,

$$\boxed{\frac{1}{2} \leq x \leq 3.}$$

Para la segunda unidad,

$$0 \leq -0.9 + 0.9x \leq 1.$$

Sumando 0.9,

$$0.9 \leq 0.9x \leq 1.9.$$

Dividiendo entre 0.9,

$$\boxed{1 \leq x \leq \frac{19}{9}.}$$

Para la tercera unidad,

$$0 \leq 1.1 - 0.7x \leq 1.$$

De la primera desigualdad,

$$1.1 - 0.7x \geq 0 \implies x \leq \frac{11}{7}.$$

De la segunda,

$$1.1 - 0.7x \leq 1 \implies -0.7x \leq -0.1.$$

Al dividir entre un número negativo se invierte la desigualdad:

$$x \geq \frac{1}{7}.$$

Por tanto,

$$\boxed{\frac{1}{7} \leq x \leq \frac{11}{7}.}$$

La salida completa es

$$\begin{aligned} f_{\text{rect}}(x) = & -0.23 - 1.3 \text{rect}(-0.2 + 0.4x) \\ & + 1.3 \text{rect}(-0.9 + 0.9x) + 0.66 \text{rect}(1.1 - 0.7x). \end{aligned}$$

Ordenando los puntos de cambio,

$$\frac{1}{7} < \frac{1}{2} < 1 < \frac{11}{7} < \frac{19}{9} < 3.$$

La función por regiones es

$$f_{\text{rect}}(x) = \begin{cases} -0.23, & x < \frac{1}{7}, \\ 0.43, & \frac{1}{7} \leq x < \frac{1}{2}, \\ -0.87, & \frac{1}{2} \leq x < 1, \\ 0.43, & 1 \leq x \leq \frac{11}{7}, \\ -0.23, & \frac{11}{7} < x \leq \frac{19}{9}, \\ -1.53, & \frac{19}{9} < x \leq 3, \\ -0.23, & x > 3. \end{cases}$$

Esta función también es constante por partes, pero cada unidad puede introducir dos saltos: uno cuando se activa y otro cuando vuelve a desactivarse.

Función sinusoidal

Para

$$a(z) = \sin(z),$$

la salida de la red es

$$f_{\text{sin}}(x) = -0.23 - 1.3 \sin(-0.2 + 0.4x) + 1.3 \sin(-0.9 + 0.9x) + 0.66 \sin(1.1 - 0.7x).$$

Cada unidad produce una onda sinusoidal con una amplitud, una frecuencia y un desplazamiento distintos. La suma de estas ondas genera una función suave y oscilatoria.

En general, una red con activación sinusoidal representa funciones de la forma

$$f(x) = \phi_0 + \sum_{d=1}^D \phi_d \sin(\theta_{d0} + \theta_{d1}x).$$

2.9 Problema 3.8

Se encuentran en el cuaderno de Google Colab

2.10 Problema 3.9

Las pendientes de las cuatro regiones lineales de la figura 3.3 son

$$m_1 = \phi_3\theta_{31},$$

$$m_2 = \phi_1\theta_{11} + \phi_3\theta_{31},$$

$$m_3 = \phi_1\theta_{11} + \phi_2\theta_{21} + \phi_3\theta_{31},$$

y

$$m_4 = \phi_1\theta_{11} + \phi_2\theta_{21}.$$

Sumamos las pendientes de la primera y la cuarta región:

$$\begin{aligned} m_1 + m_4 &= \phi_3\theta_{31} + \phi_1\theta_{11} + \phi_2\theta_{21} \\ &= \phi_1\theta_{11} + \phi_2\theta_{21} + \phi_3\theta_{31}. \end{aligned}$$

Pero esta expresión es exactamente la pendiente de la tercera región:

$$m_3 = \phi_1\theta_{11} + \phi_2\theta_{21} + \phi_3\theta_{31}.$$

Por tanto,

$$\boxed{m_3 = m_1 + m_4.}$$

Esto ocurre porque en la primera región solamente contribuye la tercera unidad oculta, mientras que en la cuarta contribuyen la primera y la segunda. En la tercera región están activas las tres unidades.

2.11 Problema 3.10

Una red con una entrada, tres unidades ocultas ReLU y una salida puede generar como máximo tres puntos de cambio y, por tanto, cuatro regiones lineales.

Sin embargo, la red puede producir menos de cuatro regiones en varias situaciones.

Puntos de cambio coincidentes

El punto de cambio de la unidad d está dado por

$$x_d^* = -\frac{\theta_{d0}}{\theta_{d1}}.$$

Si dos unidades cumplen

$$-\frac{\theta_{10}}{\theta_{11}} = -\frac{\theta_{20}}{\theta_{21}},$$

sus cambios ocurren en la misma posición. En este caso se generan menos regiones.

Peso de salida igual a cero

Si

$$\phi_d = 0,$$

entonces

$$\phi_d h_d = 0.$$

Aunque la unidad se active o se desactive, no tiene ningún efecto sobre la salida.

Preactivación constante

Si

$$\theta_{d1} = 0,$$

entonces

$$h_d = \text{ReLU}(\theta_{d0})$$

es constante y no produce un punto de cambio.

Cancelación de pendientes

Si varias unidades cambian en el mismo punto, el cambio total de pendiente es

$$\Delta m = \sum_{d \in \mathcal{C}} \phi_d \theta_{d1},$$

donde $\mathcal{C}$ es el conjunto de unidades que cambian en ese punto.

Si

$$\sum_{d \in \mathcal{C}} \phi_d \theta_{d1} = 0,$$

el cambio de pendiente se cancela y el quiebre no aparece en la salida.

Dominio limitado

También puede ocurrir que un punto de cambio se encuentre fuera del intervalo que se está estudiando. En ese caso, ese quiebre no se observa dentro del dominio considerado.

Por tanto, la red produce menos de cuatro regiones cuando algunos quiebres coinciden, se cancelan, no tienen efecto sobre la salida o se encuentran fuera del dominio.

2.12 Problema 3.11

La red de la figura 3.6 tiene una entrada, cuatro unidades ocultas y dos salidas.

Cada unidad oculta recibe una entrada y tiene un término independiente. Por tanto, cada unidad oculta tiene

$$1 \text{ peso} + 1 \text{ sesgo} = 2$$

parámetros.

Como hay cuatro unidades ocultas,

$$4(2) = 8$$

parámetros corresponden a la primera capa.

Cada una de las dos salidas recibe las cuatro unidades ocultas y tiene su propio sesgo. Por tanto, cada salida tiene

$$4 \text{ pesos} + 1 \text{ sesgo} = 5$$

parámetros.

Las dos salidas contienen

$$2(5) = 10$$

parámetros.

El número total es

$$8 + 10 = 18.$$

Por tanto,

la red de la figura 3.6 tiene 18 parámetros.

2.13 Problema 3.12

La red de la figura 3.7 tiene dos entradas, tres unidades ocultas y una salida.

Cada unidad oculta recibe las dos entradas y tiene un sesgo. Por tanto, cada unidad contiene

$$2 \text{ pesos} + 1 \text{ sesgo} = 3$$

parámetros.

Como existen tres unidades ocultas,

$$3(3) = 9$$

parámetros pertenecen a la primera capa.

La salida recibe las tres unidades ocultas y tiene un sesgo. Por tanto, contiene

$$3 \text{ pesos} + 1 \text{ sesgo} = 4$$

parámetros.

El total es

$$9 + 4 = 13.$$

Por consiguiente,

la red de la figura 3.7 tiene 13 parámetros.

2.14 Problema 3.13

La figura 3.8 contiene tres unidades ocultas. Cada una define una recta que divide el plano en una parte activa y una parte inactiva.

Denotamos las rectas como

$$\mathcal{L}_1 : \theta_{10} + \theta_{11}x_1 + \theta_{12}x_2 = 0,$$

$$\mathcal{L}_2 : \theta_{20} + \theta_{21}x_1 + \theta_{22}x_2 = 0,$$

y

$$\mathcal{L}_3 : \theta_{30} + \theta_{31}x_1 + \theta_{32}x_2 = 0.$$

Una unidad h_d está activa cuando

$$\theta_{d0} + \theta_{d1}x_1 + \theta_{d2}x_2 > 0,$$

y está inactiva cuando esta expresión es menor o igual que cero.

Los patrones de activación de las siete regiones son

Región	Unidades activas	Unidades inactivas
Inferior izquierda	h_3	h_1, h_2
Izquierda central	ninguna	h_1, h_2, h_3
Superior izquierda	h_1	h_2, h_3
Triangular central	h_1, h_3	h_2
Inferior derecha exterior	h_2, h_3	h_1
Inferior derecha central	h_1, h_2, h_3	ninguna
Superior derecha	h_1, h_2	h_3

También se puede representar cada patrón mediante una terna

$$(a_1, a_2, a_3),$$

donde $a_d = 1$ indica que la unidad está activa y $a_d = 0$ indica que está inactiva.

Los siete patrones son

$$\boxed{(0, 0, 1), (0, 0, 0), (1, 0, 0), (1, 0, 1), (0, 1, 1), (1, 1, 1), (1, 1, 0)}.$$

El único patrón que no aparece es

$$\boxed{(0, 1, 0)}.$$

2.15 Problema 3.14

La red de la figura 3.11 tiene tres entradas,

$$x_1, \quad x_2, \quad x_3,$$

tres unidades ocultas,

$$h_1, \quad h_2, \quad h_3,$$

y dos salidas,

$$y_1, \quad y_2.$$

Las tres unidades ocultas se calculan mediante

$$h_1 = a(\theta_{10} + \theta_{11}x_1 + \theta_{12}x_2 + \theta_{13}x_3)$$

$$h_2 = a(\theta_{20} + \theta_{21}x_1 + \theta_{22}x_2 + \theta_{23}x_3)$$

y

$$h_3 = a(\theta_{30} + \theta_{31}x_1 + \theta_{32}x_2 + \theta_{33}x_3).$$

Si la activación utilizada es ReLU,

$$a(z) = \text{ReLU}(z) = \max(0, z).$$

Las dos salidas son combinaciones lineales de las unidades ocultas:

$$y_1 = \phi_{10} + \phi_{11}h_1 + \phi_{12}h_2 + \phi_{13}h_3$$

y

$$y_2 = \phi_{20} + \phi_{21}h_1 + \phi_{22}h_2 + \phi_{23}h_3.$$

2.16 Problema 3.15

La red de la figura 3.11 tiene

$$D_i = 3$$

dimensiones de entrada y

$$D = 3$$

unidades ocultas.

Cada unidad oculta ReLU crea un plano en el espacio tridimensional:

$$\theta_{d0} + \theta_{d1}x_1 + \theta_{d2}x_2 + \theta_{d3}x_3 = 0.$$

El número máximo de regiones creadas por D hiperplanos en un espacio de dimensión D_i es

$$R_{\max} = \sum_{j=0}^{D_i} \binom{D}{j}.$$

Sustituyendo $D_i = 3$ y $D = 3$,

$$R_{\max} = \binom{3}{0} + \binom{3}{1} + \binom{3}{2} + \binom{3}{3}.$$

Calculando,

$$\binom{3}{0} = 1, \quad \binom{3}{1} = 3, \quad \binom{3}{2} = 3, \quad \binom{3}{3} = 1.$$

Entonces,

$$R_{\max} = 1 + 3 + 3 + 1 = 8.$$

Por tanto,

$$\boxed{R_{\max} = 8.}$$

Este máximo se alcanza cuando los tres planos están en posición general. La cantidad de salidas no cambia el número de regiones, ya que estas son creadas por las unidades ocultas en el espacio de entrada.

2.17 Problema 3.16

Consideramos una red con dos entradas,

$$x_1, \quad x_2,$$

cuatro unidades ocultas,

$$h_1, \quad h_2, \quad h_3, \quad h_4,$$

y tres salidas,

$$y_1, \quad y_2, \quad y_3.$$

Las cuatro unidades ocultas están definidas por

$$\boxed{h_1 = a(\theta_{10} + \theta_{11}x_1 + \theta_{12}x_2)}$$

$$\boxed{h_2 = a(\theta_{20} + \theta_{21}x_1 + \theta_{22}x_2)}$$

$$\boxed{h_3 = a(\theta_{30} + \theta_{31}x_1 + \theta_{32}x_2)}$$

y

$$h_4 = a (\theta_{40} + \theta_{41}x_1 + \theta_{42}x_2).$$

Las tres salidas son

$$y_1 = \phi_{10} + \phi_{11}h_1 + \phi_{12}h_2 + \phi_{13}h_3 + \phi_{14}h_4$$

$$y_2 = \phi_{20} + \phi_{21}h_1 + \phi_{22}h_2 + \phi_{23}h_3 + \phi_{24}h_4$$

y

$$y_3 = \phi_{30} + \phi_{31}h_1 + \phi_{32}h_2 + \phi_{33}h_3 + \phi_{34}h_4.$$

De forma compacta,

$$h_d = a \left(\theta_{d0} + \sum_{i=1}^2 \theta_{di}x_i \right), \quad d = 1, \dots, 4,$$

y

$$y_j = \phi_{j0} + \sum_{d=1}^4 \phi_{jd}h_d, \quad j = 1, 2, 3.$$

La arquitectura de la red puede representarse de forma esquemática como

$$\begin{array}{ccccc} x_1 & \searrow & h_1, h_2, h_3, h_4 & \nearrow & y_1 \\ & \longrightarrow & \text{capa oculta} & \longrightarrow & y_2 \\ x_2 & \nearrow & & \searrow & y_3 \end{array}$$

Cada una de las dos entradas está conectada con las cuatro unidades ocultas, y cada unidad oculta está conectada con las tres salidas.

2.18 Problema 3.17

La red general tiene

$$D_i$$

entradas,

$$D$$

unidades ocultas y

$$D_o$$

salidas.

Cada unidad oculta está definida por

$$h_d = a \left[\theta_{d0} + \sum_{i=1}^{D_i} \theta_{di} x_i \right].$$

Cada unidad contiene un peso por cada entrada y un sesgo. Por tanto, cada unidad oculta tiene

$$D_i + 1$$

parámetros.

Como hay D unidades ocultas, la primera capa contiene

$$D(D_i + 1)$$

parámetros.

Cada salida está definida por

$$y_j = \phi_{j0} + \sum_{d=1}^D \phi_{jd} h_d.$$

Cada salida contiene un peso para cada unidad oculta y un sesgo. Por tanto, cada salida tiene

$$D + 1$$

parámetros.

Como hay D_o salidas, la segunda capa contiene

$$D_o(D + 1)$$

parámetros.

Sumando las dos capas,

$$N_{\text{par}} = D(D_i + 1) + D_o(D + 1).$$

Por tanto,

$$\boxed{N_{\text{par}} = D(D_i + 1) + D_o(D + 1).}$$

Desarrollando,

$$\boxed{N_{\text{par}} = D_i D + D + D_o D + D_o.}$$

2.19 Problema 3.18

El resultado de Zaslavsky establece que el número máximo de regiones creadas por D hiperplanos en un espacio de dimensión D_i es

$$R_{\max} = \sum_{j=0}^{D_i} \binom{D_i}{j}.$$

En este problema,

$$D_i = 2$$

y

$$D = 3.$$

Por tanto,

$$R_{\max} = \sum_{j=0}^2 \binom{3}{j}.$$

Desarrollando,

$$R_{\max} = \binom{3}{0} + \binom{3}{1} + \binom{3}{2}.$$

Calculamos cada término:

$$\binom{3}{0} = 1,$$

$$\binom{3}{1} = 3,$$

y

$$\binom{3}{2} = \frac{3!}{2!1!} = 3.$$

Entonces,

$$R_{\max} = 1 + 3 + 3 = 7.$$

Por tanto,

$$\boxed{R_{\max} = 7.}$$

Esto corresponde a tres rectas en posición general, es decir, sin rectas paralelas y sin que las tres pasen por un mismo punto.

Ahora agregamos dos unidades ocultas, de modo que

$$D = 5.$$

El número máximo de regiones es

$$R_{\max} = \sum_{j=0}^2 \binom{5}{j}.$$

Desarrollando,

$$R_{\max} = \binom{5}{0} + \binom{5}{1} + \binom{5}{2}.$$

Tenemos

$$\binom{5}{0} = 1,$$

$$\binom{5}{1} = 5,$$

y

$$\binom{5}{2} = \frac{5!}{2!3!} = \frac{5 \cdot 4}{2} = 10.$$

Por tanto,

$$R_{\max} = 1 + 5 + 10 = 16.$$

Finalmente,

$\begin{array}{ll} D = 3 & \implies R_{\max} = 7, \\ D = 5 & \implies R_{\max} = 16. \end{array}$

3 Ejericicos Capitulo 4

3.1 Problema 4.1

En la figura 4.8 se tienen dos redes neuronales conectadas una después de la otra. La primera red recibe x y produce una salida y :

$$y = f(x).$$

Luego, la segunda red utiliza este valor como entrada y produce la salida final y' :

$$y' = g(y).$$

Al sustituir la salida de la primera red en la segunda, la función completa queda dada por

$$y' = g(f(x)).$$

Las dos funciones son lineales por partes. Sin embargo, al realizar la composición, cada región lineal de $f(x)$ puede atravesar varios puntos de cambio de $g(y)$. Por esta razón, la función final tiene más regiones lineales que cada una de las redes por separado.

La construcción de la función compuesta, el cálculo de sus puntos de cambio y la gráfica de y' respecto a x se presentan en el cuaderno de Google Colab correspondiente al problema 4.1.

3.2 Problema 4.2

En la figura 4.6 se muestra una red neuronal profunda con una entrada vectorial, tres capas ocultas y una salida vectorial.

Los cuatro hiperparámetros que describen su arquitectura son los siguientes.

Dimensión de la entrada

La entrada tiene tres componentes:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}.$$

Por tanto,

$$D_i = 3.$$

Número de capas ocultas

La red contiene las capas ocultas

$$\mathbf{h}_1, \quad \mathbf{h}_2, \quad \mathbf{h}_3.$$

Por consiguiente, el número de capas ocultas es

$$K = 3.$$

Número de unidades en cada capa oculta

La primera capa oculta tiene cuatro unidades, la segunda tiene dos y la tercera tiene tres. Por tanto,

$$D_1 = 4, \quad D_2 = 2, \quad D_3 = 3.$$

También se puede escribir el ancho de las capas como el vector

$$(D_1, D_2, D_3) = (4, 2, 3).$$

Dimensión de la salida

La red produce dos valores de salida:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

Por tanto,

$$\boxed{D_o = 2.}$$

En resumen, los cuatro tipos de hiperparámetros de la arquitectura son

$$\boxed{D_i = 3, \quad K = 3, \quad (D_1, D_2, D_3) = (4, 2, 3), \quad D_o = 2.}$$

Aunque aparecen varios valores numéricos para los anchos, estos forman un solo conjunto de hiperparámetros que determina el tamaño de cada capa oculta.

Los tamaños de las matrices de pesos se obtienen a partir del número de unidades de dos capas consecutivas:

$$\mathbf{\Omega}_0 \in \mathbb{R}^{4 \times 3},$$

$$\mathbf{\Omega}_1 \in \mathbb{R}^{2 \times 4},$$

$$\mathbf{\Omega}_2 \in \mathbb{R}^{3 \times 2},$$

y

$$\mathbf{\Omega}_3 \in \mathbb{R}^{2 \times 3}.$$

De igual manera, los vectores de sesgos tienen dimensiones

$$\boldsymbol{\beta}_0 \in \mathbb{R}^4, \quad \boldsymbol{\beta}_1 \in \mathbb{R}^2, \quad \boldsymbol{\beta}_2 \in \mathbb{R}^3, \quad \boldsymbol{\beta}_3 \in \mathbb{R}^2.$$

3.3 Problema 4.3

Queremos demostrar la siguiente igualdad:

$$\begin{aligned} & \text{ReLU} [\boldsymbol{\beta}_1 + \lambda_1 \mathbf{\Omega}_1 \text{ReLU} [\boldsymbol{\beta}_0 + \lambda_0 \mathbf{\Omega}_0 \mathbf{x}]] \\ &= \lambda_0 \lambda_1 \text{ReLU} \left[\frac{1}{\lambda_0 \lambda_1} \boldsymbol{\beta}_1 + \mathbf{\Omega}_1 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \mathbf{\Omega}_0 \mathbf{x} \right] \right]. \end{aligned}$$

La propiedad de homogeneidad no negativa de la función ReLU establece que

$$\text{ReLU}(\alpha \mathbf{z}) = \alpha \text{ReLU}(\mathbf{z}), \quad \alpha \geq 0.$$

Cuando se trabaja con vectores, la función ReLU se aplica componente a componente.

Como en la igualdad aparecen los términos $1/\lambda_0$ y $1/(\lambda_0 \lambda_1)$, se supone que

$$\lambda_0 > 0, \quad \lambda_1 > 0.$$

Comenzamos con la parte interna de la red:

$$\text{ReLU} [\boldsymbol{\beta}_0 + \lambda_0 \boldsymbol{\Omega}_0 \mathbf{x}].$$

Podemos factorizar λ_0 dentro del argumento:

$$\boldsymbol{\beta}_0 + \lambda_0 \boldsymbol{\Omega}_0 \mathbf{x} = \lambda_0 \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right].$$

Por tanto,

$$\text{ReLU} [\boldsymbol{\beta}_0 + \lambda_0 \boldsymbol{\Omega}_0 \mathbf{x}] = \text{ReLU} \left[\lambda_0 \left(\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right) \right].$$

Aplicando la homogeneidad no negativa,

$$\boxed{\text{ReLU} [\boldsymbol{\beta}_0 + \lambda_0 \boldsymbol{\Omega}_0 \mathbf{x}] = \lambda_0 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right].}$$

Ahora sustituimos este resultado en la expresión de la segunda capa:

$$\begin{aligned} & \text{ReLU} [\boldsymbol{\beta}_1 + \lambda_1 \boldsymbol{\Omega}_1 \text{ReLU} [\boldsymbol{\beta}_0 + \lambda_0 \boldsymbol{\Omega}_0 \mathbf{x}]] \\ &= \text{ReLU} \left[\boldsymbol{\beta}_1 + \lambda_1 \boldsymbol{\Omega}_1 \left(\lambda_0 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right] \right) \right]. \end{aligned}$$

Agrupando los escalares,

$$= \text{ReLU} \left[\boldsymbol{\beta}_1 + \lambda_0 \lambda_1 \boldsymbol{\Omega}_1 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right] \right].$$

Ahora factorizamos $\lambda_0 \lambda_1$ en todo el argumento de la ReLU exterior:

$$\begin{aligned} & \boldsymbol{\beta}_1 + \lambda_0 \lambda_1 \boldsymbol{\Omega}_1 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right] \\ &= \lambda_0 \lambda_1 \left[\frac{1}{\lambda_0 \lambda_1} \boldsymbol{\beta}_1 + \boldsymbol{\Omega}_1 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right] \right]. \end{aligned}$$

Entonces,

$$\begin{aligned} & \text{ReLU} \left[\boldsymbol{\beta}_1 + \lambda_0 \lambda_1 \boldsymbol{\Omega}_1 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right] \right] \\ &= \text{ReLU} \left[\lambda_0 \lambda_1 \left(\frac{1}{\lambda_0 \lambda_1} \boldsymbol{\beta}_1 + \boldsymbol{\Omega}_1 \text{ReLU} \left[\frac{1}{\lambda_0} \boldsymbol{\beta}_0 + \boldsymbol{\Omega}_0 \mathbf{x} \right] \right) \right]. \end{aligned}$$

Aplicando nuevamente la homogeneidad de ReLU,

$$\begin{aligned} & \text{ReLU} [\beta_1 + \lambda_1 \Omega_1 \text{ReLU} [\beta_0 + \lambda_0 \Omega_0 \mathbf{x}]] \\ &= \lambda_0 \lambda_1 \text{ReLU} \left[\frac{1}{\lambda_0 \lambda_1} \beta_1 + \Omega_1 \text{ReLU} \left[\frac{1}{\lambda_0} \beta_0 + \Omega_0 \mathbf{x} \right] \right]. \end{aligned}$$

Con esto queda demostrada la igualdad.

El resultado muestra que las matrices de pesos pueden multiplicarse por factores positivos, siempre que los sesgos se ajusten de manera correspondiente. Los factores retirados pueden colocarse nuevamente al final de la red sin cambiar la función representada.

3.4 Problema 4.4

La red tiene cinco entradas, cuatro salidas y tres capas ocultas con tamaños

$$D_i = 5, \quad D_1 = 20, \quad D_2 = 10, \quad D_3 = 7, \quad D_o = 4.$$

Por tanto, los vectores que aparecen en la red tienen dimensiones

$$\mathbf{x} \in \mathbb{R}^5, \quad \mathbf{h}_1 \in \mathbb{R}^{20}, \quad \mathbf{h}_2 \in \mathbb{R}^{10},$$

$$\mathbf{h}_3 \in \mathbb{R}^7, \quad \mathbf{y} \in \mathbb{R}^4.$$

Forma de la ecuación 4.15

La primera capa oculta se calcula como

$$\mathbf{h}_1 = a [\beta_0 + \Omega_0 \mathbf{x}].$$

La segunda capa oculta es

$$\mathbf{h}_2 = a [\beta_1 + \Omega_1 \mathbf{h}_1].$$

La tercera capa oculta está dada por

$$\mathbf{h}_3 = a [\beta_2 + \Omega_2 \mathbf{h}_2].$$

Finalmente, la salida de la red es

$$\mathbf{y} = \beta_3 + \Omega_3 \mathbf{h}_3.$$

La función de activación $a(\cdot)$ se aplica componente por componente en cada capa oculta. La última capa es lineal.

Forma de la ecuación 4.16

Sustituyendo cada capa dentro de la siguiente, la red completa puede escribirse como una sola expresión:

$$\mathbf{y} = \beta_3 + \Omega_3 a [\beta_2 + \Omega_2 a [\beta_1 + \Omega_1 a [\beta_0 + \Omega_0 \mathbf{x}]]].$$

Ahora determinamos las dimensiones de los parámetros.

La matriz $\mathbf{\Omega}_0$ transforma una entrada de dimensión 5 en una capa de dimensión 20. Por tanto,

$$\mathbf{\Omega}_0 \in \mathbb{R}^{20 \times 5}, \quad \beta_0 \in \mathbb{R}^{20}.$$

La matriz $\mathbf{\Omega}_1$ transforma los 20 valores de la primera capa en los 10 valores de la segunda:

$$\mathbf{\Omega}_1 \in \mathbb{R}^{10 \times 20}, \quad \beta_1 \in \mathbb{R}^{10}.$$

La matriz $\mathbf{\Omega}_2$ transforma una capa de dimensión 10 en una capa de dimensión 7:

$$\mathbf{\Omega}_2 \in \mathbb{R}^{7 \times 10}, \quad \beta_2 \in \mathbb{R}^7.$$

Finalmente, la matriz $\mathbf{\Omega}_3$ transforma la tercera capa, que tiene 7 unidades, en las 4 salidas:

$$\mathbf{\Omega}_3 \in \mathbb{R}^{4 \times 7}, \quad \beta_3 \in \mathbb{R}^4.$$

En resumen,

k	$\mathbf{\Omega}_k$	β_k
0	$\mathbb{R}^{20 \times 5}$	$\mathbb{R}^{20}$
1	$\mathbb{R}^{10 \times 20}$	$\mathbb{R}^{10}$
2	$\mathbb{R}^{7 \times 10}$	$\mathbb{R}^7$
3	$\mathbb{R}^{4 \times 7}$	$\mathbb{R}^4$

3.5 Problema 4.5

La profundidad de una red corresponde al número de capas ocultas, mientras que el ancho corresponde al número de unidades que contiene cada capa.

En este caso se tiene

$$K = 20$$

capas ocultas. Por tanto, la profundidad es

$$\text{Profundidad} = 20.$$

Cada capa oculta contiene

$$D = 30$$

unidades. Por tanto, el ancho es

$$\text{Ancho} = 30.$$

La capa de entrada y la capa de salida no se cuentan como capas ocultas al determinar la profundidad.

3.6 Problema 4.6

La red tiene una entrada, una salida, $K = 10$ capas ocultas y $D = 10$ unidades en cada capa.

En este ejercicio se pide comparar solamente el número de pesos, por lo que no se incluyen los sesgos.

La primera matriz de pesos conecta la entrada con la primera capa oculta. Su tamaño es

$$D \times 1,$$

por lo que contiene D pesos.

Entre las K capas ocultas existen

$$K - 1$$

conexiones. Cada una utiliza una matriz de tamaño

$$D \times D,$$

por lo que aporta D^2 pesos.

Finalmente, la última capa oculta se conecta con una salida y aporta otros D pesos.

El número total de pesos es

$$W(K, D) = D + (K - 1)D^2 + D.$$

Por tanto,

$$\boxed{W(K, D) = 2D + (K - 1)D^2.}$$

Para $K = 10$ y $D = 10$,

$$\begin{aligned} W(10, 10) &= 2(10) + (10 - 1)(10)^2 \\ &= 20 + 9(100) \\ &= 920. \end{aligned}$$

Aumento de la profundidad en una unidad

Si aumentamos la profundidad de $K = 10$ a $K = 11$, aparece una nueva matriz de tamaño

$$10 \times 10.$$

El nuevo número de pesos es

$$\begin{aligned} W(11, 10) &= 2(10) + (11 - 1)(10)^2 \\ &= 20 + 10(100) \\ &= 1020. \end{aligned}$$

El aumento es

$$1020 - 920 = 100$$

pesos.

Aumento del ancho en una unidad

Ahora mantenemos $K = 10$, pero cambiamos el ancho de $D = 10$ a $D = 11$:

$$\begin{aligned} W(10, 11) &= 2(11) + (10 - 1)(11)^2 \\ &= 22 + 9(121) \\ &= 22 + 1089 \\ &= 1111. \end{aligned}$$

El aumento es

$$1111 - 920 = 191$$

pesos.

Como

$$191 > 100,$$

se concluye que

aumentar el ancho en una unidad agrega más pesos que aumentar la profundidad en una unidad.

Esto ocurre porque aumentar la profundidad agrega solamente una nueva matriz $D \times D$, mientras que aumentar el ancho modifica todas las matrices de la red.

3.7 Problema 4.7

La red neuronal superficial de la ecuación 3.1 está dada por

$$f(x) = \phi_0 + \phi_1 \text{ReLU}(\theta_{10} + \theta_{11}x) + \phi_2 \text{ReLU}(\theta_{20} + \theta_{21}x) + \phi_3 \text{ReLU}(\theta_{30} + \theta_{31}x).$$

Queremos que la salida sea la función identidad en el intervalo $[a, b]$:

$$f(x) = x, \quad x \in [a, b].$$

Podemos utilizar solamente la primera unidad oculta y hacer que las otras dos no contribuyan. Elegimos

$$\boxed{\phi_0 = a, \quad \phi_1 = 1, \quad \phi_2 = 0, \quad \phi_3 = 0.}$$

Para la primera unidad tomamos

$$\boxed{\theta_{10} = -a, \quad \theta_{11} = 1.}$$

Los parámetros de las otras unidades pueden elegirse como cero:

$$\boxed{\theta_{20} = \theta_{21} = \theta_{30} = \theta_{31} = 0.}$$

Con estos valores, la red se convierte en

$$f(x) = a + \text{ReLU}(x - a).$$

Para todo $x \in [a, b]$, se cumple

$$x - a \geq 0.$$

Por tanto,

$$\text{ReLU}(x - a) = x - a.$$

Sustituyendo,

$$\begin{aligned} f(x) &= a + (x - a) \\ &= x. \end{aligned}$$

En consecuencia,

$$\boxed{f(x) = x, \quad x \in [a, b].}$$

Fuera del intervalo, especialmente cuando $x < a$, no es necesario que la red se comporte como la identidad.

3.8 Problema 4.8

Las activaciones de las tres unidades ocultas son

$$h_1(x) = \text{ReLU}\left(x - \frac{1}{6}\right),$$

$$h_2(x) = \text{ReLU}\left(x - \frac{2}{6}\right),$$

y

$$h_3(x) = \text{ReLU}\left(\frac{4}{6} - x\right).$$

La salida de la red es

$$f(x) = \phi_0 + \phi_1 h_1(x) + \phi_2 h_2(x) + \phi_3 h_3(x).$$

Se busca que la función pase por los puntos

$$(0, 0), \quad \left(\frac{1}{6}, 1\right), \quad \left(\frac{2}{6}, 0\right), \quad \left(\frac{4}{6}, 1\right), \quad (1, 0).$$

En la primera región, la función debe pasar de 0 a 1 en un intervalo de longitud $1/6$. Por tanto, su pendiente debe ser

$$m_1 = \frac{1 - 0}{1/6 - 0} = 6.$$

En esta región solamente está activa h_3 , cuya pendiente es -1 . Entonces,

$$-\phi_3 = 6,$$

de donde

$$\boxed{\phi_3 = -6.}$$

En la segunda región, la función pasa de 1 a 0 en un intervalo de longitud $1/6$. Su pendiente es

$$m_2 = -6.$$

En esta región están activas h_1 y h_3 , así que

$$\phi_1 - \phi_3 = -6.$$

Sustituyendo $\phi_3 = -6$,

$$\phi_1 + 6 = -6,$$

por lo tanto,

$$\boxed{\phi_1 = -12.}$$

En la tercera región, la función pasa de 0 a 1 entre $x = 2/6$ y $x = 4/6$. La pendiente es

$$m_3 = \frac{1 - 0}{4/6 - 2/6} = 3.$$

Las tres unidades están activas, por lo que

$$\phi_1 + \phi_2 - \phi_3 = 3.$$

Sustituyendo los valores conocidos,

$$-12 + \phi_2 + 6 = 3.$$

Entonces,

$$\boxed{\phi_2 = 9.}$$

Finalmente, utilizamos la condición

$$f(0) = 0.$$

En $x = 0$,

$$h_1(0) = 0, \quad h_2(0) = 0, \quad h_3(0) = \frac{4}{6}.$$

Por tanto,

$$0 = \phi_0 + \phi_3 \frac{4}{6}.$$

Sustituyendo $\phi_3 = -6$,

$$0 = \phi_0 - 4,$$

y así,

$$\boxed{\phi_0 = 4.}$$

Los parámetros buscados son

$$\boxed{\phi_0 = 4, \quad \phi_1 = -12, \quad \phi_2 = 9, \quad \phi_3 = -6.}$$

La función completa es

$$\boxed{\begin{aligned} f(x) = & 4 - 12 \operatorname{ReLU}\left(x - \frac{1}{6}\right) \\ & + 9 \operatorname{ReLU}\left(x - \frac{2}{6}\right) - 6 \operatorname{ReLU}\left(\frac{4}{6} - x\right). \end{aligned}}$$

Cada una de las cuatro regiones lineales recorre completamente el intervalo de salida $[0, 1]$. Al componer la función consigo misma, cada región se divide nuevamente en cuatro regiones.

Por tanto, para dos composiciones se obtienen

$$\boxed{4^2 = 16}$$

regiones lineales.

Si se compone la red consigo misma K veces, el número de regiones es

$$\boxed{R_K = 4^K.}$$

3.9 Problema 4.8

Se encuentra en Colab

3.10 Problema 4.9

Primero consideramos una red superficial con dos unidades ocultas.

Para producir tres regiones que oscilen entre cero y uno, las pendientes deben tener signos

$$+, \quad -, \quad +.$$

Como la primera y la última pendiente son positivas y diferentes de cero, una unidad debe estar activa en la parte izquierda y otra debe estar activa en la parte derecha.

Existen dos posibles configuraciones en la región central.

En la primera configuración, las dos unidades están activas en la región central. En ese caso, la pendiente central es la suma de las pendientes exteriores:

$$m_2 = m_1 + m_3.$$

Como

$$m_1 > 0 \quad \text{y} \quad m_3 > 0,$$

se tendría

$$m_2 > 0.$$

Esto contradice el hecho de que la región central debe tener pendiente negativa.

En la segunda configuración, ninguna unidad está activa en la región central. En ese caso,

$$m_2 = 0,$$

lo cual tampoco permite que la función disminuya de uno a cero.

Por tanto,

no es posible producir tres regiones oscilatorias con solamente dos unidades ocultas.

Ahora consideramos una red con cuatro unidades ocultas. En este caso sí es posible producir cinco regiones que oscilen entre cero y uno.

Un ejemplo es

$$f(x) = -4 - 3 \operatorname{ReLU}(1 - x) + 3 \operatorname{ReLU}\left(x - \frac{3}{2}\right) \\ - 2 \operatorname{ReLU}\left(x - \frac{5}{2}\right) + 2 \operatorname{ReLU}\left(\frac{7}{2} - x\right).$$

En el intervalo

$$0 \leq x \leq \frac{9}{2},$$

esta función pasa por los puntos

$$(0, 0), \quad (1, 1), \quad \left(\frac{3}{2}, 0\right), \\ \left(\frac{5}{2}, 1\right), \quad \left(\frac{7}{2}, 0\right), \quad \left(\frac{9}{2}, 1\right).$$

Sus pendientes en las cinco regiones son

$$1, \quad -2, \quad 1, \quad -1, \quad 1.$$

Los signos alternan como se necesitaba:

$$+, \quad -, \quad +, \quad -, \quad +.$$

Por tanto,

sí es posible producir cinco regiones oscilatorias con cuatro unidades ocultas.

3.11 Problema 4.10

La red tiene una entrada, una salida y K capas ocultas, cada una con D unidades.

Primero contamos los parámetros entre la entrada y la primera capa oculta. Cada una de las D unidades recibe la entrada escalar, por lo que se tienen

$$D$$

pesos. Además, cada unidad tiene un sesgo, así que hay otros

$$D$$

parámetros.

La primera capa aporta

$$D + D = 2D$$

parámetros.

Ahora contamos los parámetros entre dos capas ocultas consecutivas.

Cada capa tiene D unidades y todas las unidades de una capa están conectadas con todas las unidades de la siguiente. Por tanto, cada matriz de pesos contiene

$$D^2$$

parámetros.

La capa siguiente también tiene D sesgos. Así, cada conexión entre dos capas ocultas aporta

$$D^2 + D = D(D + 1)$$

parámetros.

Como hay K capas ocultas, existen

$$K - 1$$

conexiones entre ellas. Su aporte total es

$$(K - 1)D(D + 1).$$

Finalmente, la última capa oculta se conecta con una salida escalar. Esto requiere

$$D$$

pesos y un sesgo, es decir,

$$D + 1$$

parámetros.

Sumando todos los términos,

$$\begin{aligned} N_{\text{par}} &= 2D + (K - 1)D(D + 1) + D + 1 \\ &= 3D + 1 + (K - 1)D(D + 1). \end{aligned}$$

Por tanto,

$$\boxed{N_{\text{par}} = 3D + 1 + (K - 1)D(D + 1).}$$

3.12 Problema 4.11

La primera red es superficial y tiene

$$D = 95$$

unidades ocultas.

Una red superficial con una entrada, una salida y D unidades ocultas tiene

$$N_{\text{par}} = 3D + 1$$

parámetros.

Entonces,

$$\begin{aligned}
N_{\text{superficial}} &= 3(95) + 1 \\
&= 285 + 1 \\
&= 286.
\end{aligned}$$

Por tanto,

$$N_{\text{superficial}} = 286.$$

El número máximo de regiones lineales es

$$D + 1.$$

Así,

$$R_{\text{superficial}} = 95 + 1 = 96.$$

La segunda red es profunda y tiene

$$K = 10, \quad D = 5.$$

El número de parámetros es

$$N_{\text{profunda}} = 3D + 1 + (K - 1)D(D + 1).$$

Sustituyendo,

$$\begin{aligned}
N_{\text{profunda}} &= 3(5) + 1 + (10 - 1)(5)(5 + 1) \\
&= 15 + 1 + 9(5)(6) \\
&= 16 + 270 \\
&= 286.
\end{aligned}$$

Por tanto,

$$N_{\text{profunda}} = 286.$$

Las dos redes tienen exactamente el mismo número de parámetros.

El número máximo de regiones lineales de la red profunda es

$$R_{\text{profunda}} = (D + 1)^K.$$

Entonces,

$$\begin{aligned}
R_{\text{profunda}} &= (5 + 1)^{10} \\
&= 6^{10} \\
&= 60\,466\,176.
\end{aligned}$$

Por tanto,

$$R_{\text{profunda}} = 60\,466\,176.$$

La comparación queda

Red	Parámetros	Regiones máximas
Superficial	286	96
Profunda	286	60 466 176

Aunque las dos redes tienen el mismo número total de parámetros, la red superficial probablemente se evalúa más rápido.

La red superficial tiene únicamente una capa oculta, por lo que requiere menos operaciones secuenciales. Además, contiene

$$95 + 95 = 190$$

pesos.

La red profunda contiene

$$5 + 9(5^2) + 5 = 235$$

pesos y debe procesar las diez capas una después de otra.

Por tanto, bajo una implementación densa normal,

la red superficial sería más rápida, pero la red profunda puede crear muchas más regiones lineales.

4 Ejericicos Capitulo 5

4.1 Ejercicio 5.1

La función sigmoide logística está definida por

$$\text{sig}(z) = \frac{1}{1 + \exp(-z)}.$$

Debemos estudiar su comportamiento cuando $z \rightarrow -\infty$, cuando $z = 0$ y cuando $z \rightarrow \infty$.

Primero consideramos el caso $z \rightarrow -\infty$. En este caso,

$$-z \rightarrow \infty,$$

por lo que

$$\exp(-z) \rightarrow \infty.$$

Entonces, el denominador de la función sigmoide crece sin límite:

$$1 + \exp(-z) \rightarrow \infty.$$

Por tanto,

$$\lim_{z \rightarrow -\infty} \text{sig}(z) = \lim_{z \rightarrow -\infty} \frac{1}{1 + \exp(-z)} = 0.$$

Ahora evaluamos la función en $z = 0$:

$$\text{sig}(0) = \frac{1}{1 + \exp(0)}.$$

Como $\exp(0) = 1$, obtenemos

$$\text{sig}(0) = \frac{1}{1 + 1} = \frac{1}{2} = 0.5.$$

Finalmente, consideramos el caso $z \rightarrow \infty$. En este caso,

$$-z \rightarrow -\infty,$$

y por consiguiente,

$$\exp(-z) \rightarrow 0.$$

Por lo tanto,

$$\lim_{z \rightarrow \infty} \text{sig}(z) = \lim_{z \rightarrow \infty} \frac{1}{1 + \exp(-z)} = \frac{1}{1 + 0} = 1.$$

En conclusión,

$\lim_{z \rightarrow -\infty} \text{sig}(z) = 0, \quad \text{sig}(0) = 0.5, \quad \lim_{z \rightarrow \infty} \text{sig}(z) = 1$
--

Esto muestra que la función sigmoide transforma cualquier número real en un valor comprendido entre 0 y 1.

4.2 Ejercicio 5.2

La función de pérdida para una observación de clasificación binaria es

$$L = -(1 - y) \log [1 - \text{sig}(f[\mathbf{x}, \phi])] - y \log [\text{sig}(f[\mathbf{x}, \phi])].$$

Para simplificar la expresión, definimos

$$p = \text{sig}(f[\mathbf{x}, \phi]),$$

donde

$$0 < p < 1.$$

De esta manera, la función de pérdida se puede escribir como

$$L(p, y) = -(1 - y) \log(1 - p) - y \log(p).$$

Analizamos por separado los dos posibles valores de la etiqueta y .

Caso 1: $y = 0$.

Sustituyendo $y = 0$ en la función de pérdida, obtenemos

$$\begin{aligned} L(p, 0) &= -(1 - 0) \log(1 - p) - 0 \log(p) \\ &= -\log(1 - p). \end{aligned}$$

Por lo tanto,

$$\boxed{L(p, 0) = -\log(1 - p)}.$$

Cuando la red predice correctamente un valor cercano a $p = 0$,

$$\lim_{p \rightarrow 0} L(p, 0) = -\log(1) = 0.$$

En cambio, si la red predice incorrectamente un valor cercano a $p = 1$,

$$\lim_{p \rightarrow 1} L(p, 0) = -\log(0) = \infty.$$

Esto significa que, cuando la etiqueta real es $y = 0$, la pérdida es pequeña si la predicción está cerca de cero y aumenta rápidamente si la predicción se acerca a uno.

Caso 2: $y = 1$.

Sustituyendo $y = 1$, se obtiene

$$\begin{aligned} L(p, 1) &= -(1 - 1) \log(1 - p) - 1 \log(p) \\ &= -\log(p). \end{aligned}$$

Por tanto,

$$\boxed{L(p, 1) = -\log(p)}.$$

Cuando la red predice correctamente un valor cercano a $p = 1$,

$$\lim_{p \rightarrow 1} L(p, 1) = -\log(1) = 0.$$

Por otro lado, si la red predice incorrectamente un valor cercano a $p = 0$,

$$\lim_{p \rightarrow 0} L(p, 1) = -\log(0) = \infty.$$

En resumen, las dos funciones que deben representarse son

$$\boxed{L(p, 0) = -\log(1 - p)}$$

y

$$L(p, 1) = -\log(p).$$

La función de pérdida penaliza con mayor fuerza las predicciones incorrectas realizadas con mucha seguridad. La gráfica correspondiente se realizó mediante el código de Python incluido en el cuaderno de Colab.

4.3 Ejercicio 5.3

La distribución de von Mises para una variable angular y está dada por

$$\Pr(y \mid \mu, \kappa) = \frac{\exp[\kappa \cos(y - \mu)]}{2\pi I_0(\kappa)},$$

donde $I_0(\kappa)$ es la función de Bessel modificada de primera especie y orden cero.

El parámetro μ representa la dirección media de la distribución, mientras que κ controla su concentración alrededor de dicha dirección. Cuando κ es grande, los valores se concentran cerca de μ ; cuando κ está cerca de cero, la distribución se aproxima a una distribución uniforme sobre el círculo.

Para entrenar un modelo que prediga la dirección del viento, podemos suponer que la red produce una estimación

$$\mu = f[\mathbf{x}, \phi],$$

donde $\mathbf{x}$ contiene las mediciones de presión barométrica y ϕ representa los parámetros de la red.

La función de pérdida se obtiene tomando el negativo del logaritmo de la probabilidad:

$$L(y, \mu, \kappa) = -\log \Pr(y \mid \mu, \kappa).$$

Sustituyendo la distribución de von Mises, tenemos

$$L(y, \mu, \kappa) = -\log \left(\frac{\exp[\kappa \cos(y - \mu)]}{2\pi I_0(\kappa)} \right).$$

Utilizando la propiedad

$$\log \left(\frac{a}{b} \right) = \log(a) - \log(b),$$

obtenemos

$$\begin{aligned} L(y, \mu, \kappa) &= -[\log(\exp[\kappa \cos(y - \mu)]) - \log(2\pi I_0(\kappa))] \\ &= -\kappa \cos(y - \mu) + \log(2\pi I_0(\kappa)). \end{aligned}$$

Por lo tanto, la función de pérdida asociada a la distribución de von Mises es

$$L(y, \mu, \kappa) = -\kappa \cos(y - \mu) + \log(2\pi I_0(\kappa)).$$

Si el parámetro κ se considera constante durante el entrenamiento, entonces el término

$$\log(2\pi I_0(\kappa))$$

también es constante y no afecta el valor de μ que minimiza la función. En ese caso, minimizar la pérdida es equivalente a minimizar

$$-\cos(y - \mu).$$

También puede usarse la forma equivalente

$$L_{\text{circular}}(y, \mu) = 1 - \cos(y - \mu).$$

Esta función es adecuada para datos angulares porque respeta la periodicidad. Por ejemplo, los ángulos 0 y 2π representan la misma dirección y producen una pérdida igual a cero:

$$1 - \cos(0 - 2\pi) = 1 - \cos(2\pi) = 0.$$

En cambio, utilizar directamente el error cuadrático

$$(y - \mu)^2$$

produciría un error muy grande entre 0 y 2π , aunque ambos valores representan exactamente la misma dirección.

4.4 Ejercicio 5.4

Queremos modelar una salida multimodal usando una mezcla de dos distribuciones normales. Para cada dato de entrada $\mathbf{x}_i$, la red debe producir los parámetros de la mezcla. Es decir, si

$$\theta_i = \{\lambda_i, \mu_{1,i}, \mu_{2,i}, \sigma_{1,i}^2, \sigma_{2,i}^2\},$$

entonces el modelo define

$$\Pr(y_i | \mathbf{x}_i, \phi) = \lambda_i \mathcal{N}(y_i; \mu_{1,i}, \sigma_{1,i}^2) + (1 - \lambda_i) \mathcal{N}(y_i; \mu_{2,i}, \sigma_{2,i}^2),$$

donde

$$\mathcal{N}(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right).$$

Por tanto, de forma explícita,

$$\Pr(y_i | \mathbf{x}_i, \phi) = \lambda_i \frac{1}{\sqrt{2\pi\sigma_{1,i}^2}} \exp\left(-\frac{(y_i - \mu_{1,i})^2}{2\sigma_{1,i}^2}\right) + (1-\lambda_i) \frac{1}{\sqrt{2\pi\sigma_{2,i}^2}} \exp\left(-\frac{(y_i - \mu_{2,i})^2}{2\sigma_{2,i}^2}\right).$$

La función de verosimilitud para todo el conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^I$ es

$$\Pr(\{y_i\}_{i=1}^I | \{\mathbf{x}_i\}_{i=1}^I, \phi) = \prod_{i=1}^I \Pr(y_i | \mathbf{x}_i, \phi).$$

Entonces, la función de pérdida natural es el negativo del logaritmo de la verosimilitud:

$$\mathcal{L}(\phi) = -\sum_{i=1}^I \log \left[\lambda_i \frac{1}{\sqrt{2\pi\sigma_{1,i}^2}} \exp\left(-\frac{(y_i - \mu_{1,i})^2}{2\sigma_{1,i}^2}\right) + (1-\lambda_i) \frac{1}{\sqrt{2\pi\sigma_{2,i}^2}} \exp\left(-\frac{(y_i - \mu_{2,i})^2}{2\sigma_{2,i}^2}\right) \right].$$

Esta es la pérdida que se minimiza durante el entrenamiento.

Además, para garantizar que los parámetros tengan valores válidos, normalmente se hace que la red produzca salidas intermedias $a_i, b_{1,i}, b_{2,i}, c_{1,i}, c_{2,i}$ y luego se transforman como

$$\lambda_i = \text{sig}(a_i), \quad \sigma_{1,i}^2 = \exp(c_{1,i}), \quad \sigma_{2,i}^2 = \exp(c_{2,i}),$$

de manera que se cumpla automáticamente que

$$0 \leq \lambda_i \leq 1, \quad \sigma_{1,i}^2 > 0, \quad \sigma_{2,i}^2 > 0.$$

Problemas al hacer inferencia.

El principal problema es que la distribución predicha puede ser multimodal. En ese caso, no siempre tiene sentido resumir la predicción con un único valor. Por ejemplo, si se toma la media de la mezcla,

$$\mathbb{E}[y | \mathbf{x}] = \lambda\mu_1 + (1-\lambda)\mu_2,$$

puede ocurrir que ese valor quede en una región donde la probabilidad es baja, precisamente entre los dos picos. Es decir, la media puede no representar ninguna de las soluciones plausibles.

Otro problema es el *label switching*: si intercambiamos las etiquetas de las dos componentes, es decir, si cambiamos $(\lambda, \mu_1, \sigma_1^2, \mu_2, \sigma_2^2)$ por $(1-\lambda, \mu_2, \sigma_2^2, \mu_1, \sigma_1^2)$, la distribución resultante es la misma. Por eso, los parámetros no son identificables de manera única.

También puede haber inestabilidad numérica, porque en la pérdida aparece el logaritmo de una suma de exponenciales, y esto puede causar problemas de desbordamiento o subdesbordamiento si no se implementa con cuidado.

En la práctica, para inferencia puede ser mejor:

- devolver las dos modas posibles;
- escoger la componente con mayor peso;
- o muestrear de la distribución en vez de usar solo la media.

4.5 Ejercicio 5.5

Ahora queremos predecir una dirección angular usando una mezcla de dos distribuciones de von Mises. La densidad de una distribución de von Mises es

$$\Pr(y \mid \mu, \kappa) = \frac{\exp[\kappa \cos(y - \mu)]}{2\pi I_0(\kappa)},$$

donde μ es la dirección media, κ es la concentración e $I_0(\kappa)$ es la función de Bessel modificada de orden cero.

Entonces, una mezcla de dos distribuciones de von Mises queda dada por

$$\Pr(y \mid \theta) = \lambda \frac{\exp[\kappa_1 \cos(y - \mu_1)]}{2\pi I_0(\kappa_1)} + (1 - \lambda) \frac{\exp[\kappa_2 \cos(y - \mu_2)]}{2\pi I_0(\kappa_2)}.$$

Aquí,

$$\theta = \{\lambda, \mu_1, \mu_2, \kappa_1, \kappa_2\}.$$

Por tanto, si se aprenden todos los parámetros, la red debe producir **cinco salidas**:

$$\lambda, \quad \mu_1, \quad \mu_2, \quad \kappa_1, \quad \kappa_2.$$

Ahora bien, si seguimos exactamente la simplificación del problema 5.3 y tratamos la concentración como constante, es decir, si fijamos $\kappa_1 = \kappa_2 = \kappa$, entonces la densidad se reduce a

$$\Pr(y \mid \theta) = \lambda \frac{\exp[\kappa \cos(y - \mu_1)]}{2\pi I_0(\kappa)} + (1 - \lambda) \frac{\exp[\kappa \cos(y - \mu_2)]}{2\pi I_0(\kappa)},$$

y en ese caso la red solo necesita producir **tres salidas**:

$$\lambda, \quad \mu_1, \quad \mu_2.$$

Así que la respuesta depende de si κ se fija o se aprende:

- si κ es constante, la red necesita 3 salidas;
- si κ_1 y κ_2 también se aprenden, necesita 5 salidas.

4.6 Ejercicio 5.6

Queremos modelar una variable de conteo

$$y \in \{0, 1, 2, \dots\}$$

mediante una distribución de Poisson con parámetro $\lambda > 0$. La función de probabilidad es

$$\Pr(y = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

Si la red recibe $\mathbf{x}_i$ y produce un parámetro λ_i , entonces

$$\Pr(y_i | \mathbf{x}_i, \phi) = \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}.$$

Para garantizar que $\lambda_i > 0$, normalmente se toma una salida real a_i de la red y se define, por ejemplo,

$$\lambda_i = \exp(a_i).$$

La verosimilitud del conjunto de entrenamiento es

$$\prod_{i=1}^I \frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!}.$$

Entonces, la pérdida de entrenamiento es el negativo del logaritmo de esa verosimilitud:

$$\begin{aligned} \mathcal{L}(\phi) &= - \sum_{i=1}^I \log \left(\frac{\lambda_i^{y_i} e^{-\lambda_i}}{y_i!} \right) \\ &= - \sum_{i=1}^I (y_i \log \lambda_i - \lambda_i - \log(y_i!)) \\ &= \sum_{i=1}^I (\lambda_i - y_i \log \lambda_i + \log(y_i!)). \end{aligned}$$

Por tanto, la función de pérdida es

$$\boxed{\mathcal{L}(\phi) = \sum_{i=1}^I (\lambda_i - y_i \log \lambda_i + \log(y_i!))}.$$

Como el término $\log(y_i!)$ no depende de los parámetros del modelo, durante el entrenamiento se puede omitir, y queda la forma equivalente

$$\boxed{\mathcal{L}(\phi) \equiv \sum_{i=1}^I (\lambda_i - y_i \log \lambda_i)}.$$

4.7 Ejercicio 5.7

Ahora tenemos un problema de regresión multivariada con

$$\mathbf{y} \in \mathbb{R}^{10}.$$

Supondremos que, condicionadas a la entrada $\mathbf{x}$, las diez componentes de salida son independientes y cada una sigue una distribución normal con media μ_d y varianza común constante σ^2 . Es decir,

$$\Pr(\mathbf{y} \mid \mathbf{x}, \phi) = \prod_{d=1}^{10} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_d - \mu_d)^2}{2\sigma^2}\right),$$

donde $\mu_d = f_d[\mathbf{x}, \phi]$ es la salida d -ésima de la red.

Agrupando términos, esto puede escribirse como

$$\Pr(\mathbf{y} \mid \mathbf{x}, \phi) = (2\pi\sigma^2)^{-10/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{d=1}^{10} (y_d - \mu_d)^2\right).$$

Como $10/2 = 5$, queda

$$\Pr(\mathbf{y} \mid \mathbf{x}, \phi) = (2\pi\sigma^2)^{-5} \exp\left(-\frac{1}{2\sigma^2} \sum_{d=1}^{10} (y_d - \mu_d)^2\right).$$

Para un conjunto de entrenamiento $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^I$, la pérdida es

$$\begin{aligned} \mathcal{L}(\phi) &= -\sum_{i=1}^I \log \Pr(\mathbf{y}_i \mid \mathbf{x}_i, \phi) \\ &= -\sum_{i=1}^I \left[-5 \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{d=1}^{10} (y_{i,d} - \mu_{i,d})^2 \right] \\ &= \sum_{i=1}^I \left[5 \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_{d=1}^{10} (y_{i,d} - \mu_{i,d})^2 \right]. \end{aligned}$$

Entonces,

$$\boxed{\mathcal{L}(\phi) = \sum_{i=1}^I \left[5 \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_{d=1}^{10} (y_{i,d} - \mu_{i,d})^2 \right]}.$$

Como σ^2 es constante y no se estima, el término

$$5 \log(2\pi\sigma^2)$$

es constante, y además

$$\frac{1}{2\sigma^2}$$

es solo un factor positivo constante. Por lo tanto, minimizar $\mathcal{L}(\phi)$ es equivalente a minimizar

$$\sum_{i=1}^I \sum_{d=1}^{10} (y_{i,d} - \mu_{i,d})^2.$$

Es decir, se recupera la suma de errores cuadrados usual:

$$\boxed{\min_{\phi} \mathcal{L}(\phi) \iff \min_{\phi} \sum_{i=1}^I \sum_{d=1}^{10} (y_{i,d} - \mu_{i,d})^2.}$$

4.8 Ejercicio 5.8

Ahora queremos una versión heterocedástica del problema anterior. Eso significa que la media y la varianza de cada componente pueden depender de la entrada.

Para cada dimensión $d = 1, \dots, 10$, asumimos

$$y_d \mid \mathbf{x} \sim \mathcal{N}(\mu_d, \sigma_d^2),$$

donde tanto μ_d como σ_d^2 dependen de $\mathbf{x}$ y son predichos por la red. Asumiendo independencia entre las dimensiones,

$$\Pr(\mathbf{y} \mid \mathbf{x}, \phi) = \prod_{d=1}^{10} \frac{1}{\sqrt{2\pi\sigma_d^2}} \exp\left(-\frac{(y_d - \mu_d)^2}{2\sigma_d^2}\right).$$

Para el dato $(\mathbf{x}_i, \mathbf{y}_i)$, la pérdida es

$$\begin{aligned} \mathcal{L}_i &= -\log \Pr(\mathbf{y}_i \mid \mathbf{x}_i, \phi) \\ &= -\sum_{d=1}^{10} \log \left[\frac{1}{\sqrt{2\pi\sigma_{i,d}^2}} \exp\left(-\frac{(y_{i,d} - \mu_{i,d})^2}{2\sigma_{i,d}^2}\right) \right] \\ &= \sum_{d=1}^{10} \left[\frac{1}{2} \log(2\pi\sigma_{i,d}^2) + \frac{(y_{i,d} - \mu_{i,d})^2}{2\sigma_{i,d}^2} \right]. \end{aligned}$$

Sumando sobre todo el conjunto de entrenamiento, obtenemos

$$\boxed{\mathcal{L}(\phi) = \sum_{i=1}^I \sum_{d=1}^{10} \left[\frac{1}{2} \log(2\pi\sigma_{i,d}^2) + \frac{(y_{i,d} - \mu_{i,d})^2}{2\sigma_{i,d}^2} \right].}$$

Esta es la función de pérdida buscada.

En la práctica, la red suele producir para cada dimensión una media y un parámetro libre $s_{i,d}$, y luego se define

$$\sigma_{i,d}^2 = \exp(s_{i,d}),$$

para asegurar que la varianza sea positiva.

En consecuencia, si hay 10 dimensiones de salida, la red debe producir:

- 10 medias μ_d ;
- 10 varianzas σ_d^2 (o sus log-varianzas).

En total, la red necesita **20 salidas**.

4.9 Ejercicio 5.9

Aquí queremos predecir simultáneamente:

- la altura de una persona en metros;
- su peso en kilogramos.

El problema es que ambas variables están en escalas y unidades diferentes. Por ejemplo, errores de 0.1 metros y errores de 5 kilogramos no son directamente comparables. Si usamos una pérdida como

$$(y_{\text{altura}} - \mu_{\text{altura}})^2 + (y_{\text{peso}} - \mu_{\text{peso}})^2,$$

la variable con mayor escala numérica o mayor variabilidad puede dominar la optimización. En otras palabras, el modelo puede concentrarse más en reducir el error del peso que el de la altura, o al revés, dependiendo de los rangos de valores.

Problemas que causa esto.

- La pérdida queda desbalanceada entre las dos tareas.
- Una variable puede dominar el entrenamiento.
- Los errores en distintas unidades no son comparables de forma natural.
- La interpretación probabilística del modelo puede ser pobre si se usa la misma escala para ambas salidas.

Primera solución: normalizar o estandarizar las salidas.

Una forma simple es transformar cada variable para que tenga escala comparable. Por ejemplo, usando estandarización:

$$\tilde{y}_{\text{altura}} = \frac{y_{\text{altura}} - m_{\text{altura}}}{s_{\text{altura}}}, \quad \tilde{y}_{\text{peso}} = \frac{y_{\text{peso}} - m_{\text{peso}}}{s_{\text{peso}}}.$$

Luego se entrena el modelo sobre estas variables normalizadas. Así, ambas contribuyen a la pérdida en una escala más equilibrada.

Segunda solución: usar una pérdida ponderada o un modelo con varianzas distintas.

Otra posibilidad es usar pesos diferentes para cada dimensión:

$$\mathcal{L} = w_1(y_{\text{altura}} - \mu_{\text{altura}})^2 + w_2(y_{\text{peso}} - \mu_{\text{peso}})^2,$$

donde, por ejemplo, se pueden elegir pesos inversamente proporcionales a la varianza de cada variable.

Una versión más elegante es usar un modelo probabilístico con varianzas diferentes por dimensión:

$$\mathcal{L} = \sum_{d=1}^2 \left[\frac{1}{2} \log \sigma_d^2 + \frac{(y_d - \mu_d)^2}{2\sigma_d^2} \right] + \text{constante}.$$

Así, el propio modelo ajusta cuánto debe pesar el error de cada componente. Por tanto, dos soluciones razonables son:

1. estandarizar las variables objetivo;
2. usar una pérdida ponderada o un modelo gaussiano con varianzas distintas.

4.10 Ejercicio 5.10

Queremos extender el problema 5.3 para predecir simultáneamente:

- la dirección del viento, que es una variable angular;
- la velocidad del viento, que es una variable real positiva.

Una forma natural de hacerlo es asumir independencia condicional entre ambas variables dado $\mathbf{x}$, y modelarlas con distribuciones apropiadas.

Para la dirección angular $y^{(\text{dir})}$ usamos una distribución de von Mises:

$$\Pr(y^{(\text{dir})} \mid \mathbf{x}, \phi) = \frac{\exp[\kappa \cos(y^{(\text{dir})} - \mu(\mathbf{x}))]}{2\pi I_0(\kappa)},$$

donde $\mu(\mathbf{x}) = f_{\text{dir}}[\mathbf{x}, \phi]$ es la dirección media predicha por la red y κ se toma constante, igual que en el problema 5.3.

Para la velocidad del viento $y^{(\text{vel})}$, una opción sencilla es usar una distribución normal:

$$\Pr(y^{(\text{vel})} \mid \mathbf{x}, \phi) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(y^{(\text{vel})} - m(\mathbf{x}))^2}{2\sigma^2}\right),$$

donde $m(\mathbf{x}) = f_{\text{vel}}[\mathbf{x}, \phi]$ es la velocidad media predicha y σ^2 se toma constante.

Bajo la hipótesis de independencia condicional,

$$\Pr(y^{(\text{dir})}, y^{(\text{vel})} \mid \mathbf{x}, \phi) = \Pr(y^{(\text{dir})} \mid \mathbf{x}, \phi) \Pr(y^{(\text{vel})} \mid \mathbf{x}, \phi).$$

Entonces, para un dato $(\mathbf{x}_i, y_i^{(\text{dir})}, y_i^{(\text{vel})})$, la pérdida es

$$\begin{aligned} \mathcal{L}_i &= -\log \Pr(y_i^{(\text{dir})}, y_i^{(\text{vel})} \mid \mathbf{x}_i, \phi) \\ &= -\log \Pr(y_i^{(\text{dir})} \mid \mathbf{x}_i, \phi) - \log \Pr(y_i^{(\text{vel})} \mid \mathbf{x}_i, \phi). \end{aligned}$$

Sustituyendo las expresiones anteriores, obtenemos

$$\begin{aligned}\mathcal{L}_i = & -\kappa \cos(y_i^{(\text{dir})} - \mu_i) + \log(2\pi I_0(\kappa)) \\ & + \frac{1}{2} \log(2\pi\sigma^2) + \frac{(y_i^{(\text{vel})} - m_i)^2}{2\sigma^2},\end{aligned}$$

donde

$$\mu_i = f_{\text{dir}}[\mathbf{x}_i, \phi], \quad m_i = f_{\text{vel}}[\mathbf{x}_i, \phi].$$

Por tanto, la pérdida total sobre el conjunto de entrenamiento es

$$\mathcal{L}(\phi) = \sum_{i=1}^I \left[-\kappa \cos(y_i^{(\text{dir})} - \mu_i) + \log(2\pi I_0(\kappa)) + \frac{1}{2} \log(2\pi\sigma^2) + \frac{(y_i^{(\text{vel})} - m_i)^2}{2\sigma^2} \right].$$

Si κ y σ^2 son constantes, entonces varios términos no dependen de los parámetros y la pérdida es equivalente a minimizar

$$\sum_{i=1}^I \left[1 - \cos(y_i^{(\text{dir})} - \mu_i) + \alpha (y_i^{(\text{vel})} - m_i)^2 \right],$$

donde $\alpha > 0$ es una constante.

En este modelo, la red necesita producir **dos salidas**:

- una para la dirección media μ_i ;
- una para la velocidad media m_i .

Observación. Como la velocidad del viento es positiva, en aplicaciones reales también podría ser más apropiado modelarla con una distribución Gamma o log-normal. Sin embargo, con una normal se obtiene una extensión sencilla y suficiente para este ejercicio.